/02

中文分词

- 为什么分词
- 分词的难点
- 分词标准
- 切分算法
- 性能评测
- 字典树
- 准确率评测

什么是词

词（word）是**形式**和**意义**相结合的单位，也是语言中**能够独立运用**的最小单位。

掌握一个词汇意味着知道其读音和语义

例如：英文单词“cat”具有的语义是“猫”，读音为``/kæt/''

自然语言处理算法中词通常也是基本单元

词的处理也是自然语言处理中重要的底层任务，是句法分析、文本分类、语言模型等任务的基础。

语言中的词汇

词（word）通常是由语素（Morpheme）构成。

语素又称词素，是语言中意义的最小单元。

- 语素与词不同，语素不能够独立运用而词可以。
- 只包含一个语素的词语称为**简单词**（Simple word）
- 包含多个语素的词称为**复杂词**（Complex word）

例如：“电灯”，包含 “电” 和 “灯” 两个语素

- 根据词在语言中的用途的不同，词还可以被划分为实义词和功能词
  - **实义词**包含事物、行为、属性和观念等概念。
  - **功能词**则是指没有清楚词汇意义或与之有关的明显概念的词。

词的形态学

虽然单词的形式和意义之间的关系本质上是任意的，但是由于社会的**约定俗成**，词的形式具有服从于**某种规则的内在结构**。研究单词的内部结构和其构成方式的学科称为**形态学（Morphology）**，又称构词学。

- 词是由一个或多个语素构成，语素主要分成两类: 词根（Lemma）和词缀（Affix）。
  - **词根**也称为原形或字典形，是指能在字典中查的到的语素，通常是一个词最主要的语素。
  - **词缀**是其他附着在原形上的语素，帮助在原形基础上衍生出新词，包含前缀、中缀、后缀等。

词的形态学

例如:

英语单词 unhappy 中，happy 为原形，-un 为前缀

邦托克语单词 fumikas（是强壮的）中，fikas（强壮）为原形，-um-为中缀

俄语单词 barabanshchik（鼓手）中，baraban（鼓）为原形，-shchik为后缀

有些语言的单词通常只包含一个或者两个语素，但是有一些语言的单词则包含多达十个以上的语素。

汉语中每个单词的语素都很少，也不会根据性、数、格、人称等发生形态变化。

英语中常见的词形变换

表 2.1　英语中常见词形变换

词形变化	说明	举例
屈折 Inflection	通过“词根 + 词缀”的方式构成和原形“同一类型”的词	名词后加 -s 后缀　复数名词（cat+s） 动词后加 -ed 后缀　动词的过去式（walk+ed）
派生 Derivation	通过“词根 + 词缀”的方式构成和原形“不同类型”的词	employ 添加后缀 -ee 变为 employee meaning 添加后缀 -less 变为 meaningless
复合 Compounding	通过组合多个词根构成一个新词，也称组合词	home + work → homework water + proof → waterproof
附着 Cliticization	通过‘词根 + 附着语”的方式“附着”在词根上	I’m 中的’m 代表 am 附着在 I 上 We’re 中’re 代表 are
截搭 Blending	两个词语各自的一部分拼接起来构成新词	smoke（烟）+ fog（雾）→ smog（烟雾） spoon（勺子）+ fork（叉子）→ spork（叉勺）
缩略 Acronym	短语中多个单词首字母组合在一起组合成词	NLP 代表 Natural Language Processing IT 代表 Information Technology
截短 Clipping	将长的单词截为较短的单词	demonstration 简化为 demo refrigerator 简化为 fridge

词语切分

对于绝大部分的印欧语系语言来说，词语之间通常由分隔符区分开来。

- 英语是**印欧语系**（Indo-European languages）的典型代表，英语句子中绝大部分单词之间都由空格或标点分割。
- 汉语为代表的**汉藏语系**（Sino-Tibetan languages）的语言中，单词之间通常没有分隔符。因此在对文本进行分析前，通常需要将句子切分为单词序列，称之为**词语切分**（Word Tokenization）。

输入： Let's first understand what's NLP.
输出：
Let␣ 's␣ first␣ understand␣ what␣ 's␣ NLP␣ .

词语切分

中文分词无论是最大匹配还是统计方法，其本质都是在计算机世界里模拟人类对语言的认知规律。这引导我们理解技术创新必须**尊重**语言学、文字学等基础学科的**客观规律**，培养严谨求实的科学精神。分词算法的每一次迭代，都离不开对中文特性和人类认知模式的深入探索，体现了**从实践中来、到实践中去**的科学方法论。

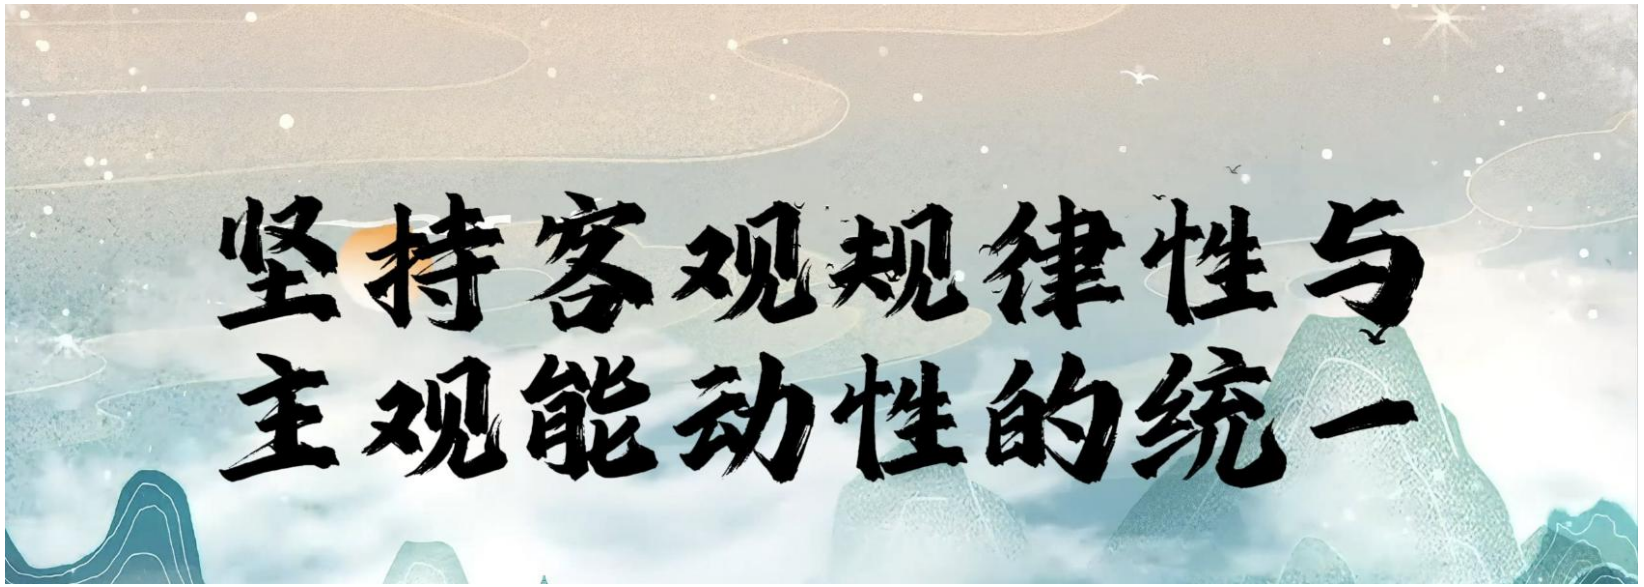

词语切分

英语句子中绝大部分的单词可以通过空格和标点符号为分隔符进行识别，但是还是存在一些例外情况

例如：缩写（Prof.），　日期（02/18/2022），数字（562,000），连字符（upper-case）等。

需要特别注意的是，上例中Let's被切分为 Let␣ 's

词形(Token)指的是在一个特定文档中的某个能够表达语义含义的字符序列。

大部分情况下词形和单词没有区别，但对于某些场景和算法有必要对单词和词形进行区分。

词语切分

在英语中，一些特殊的符号和数字也需要完整的保留到一起。

- 比如数字（ 67.20）、时间（22:37）、微博话题标签（#北京2022年冬奥会#）、Email地址（cs_nlp@fudan.edu.cn）等。
- 在特定的应用中有时也会将 Hong Kong，Head, Shoulders, Knees and Toes划分为一个词形

词形还原

词形还原（Lemmatization）是将词的各种变化形式还原其词根的过程。通过词形还原可以实现词语的规范化，单词的不同变化形式统一为词根。

例如：原始输入句：They are working on interesting tasks
词形还原后：they be work on interesting task

词形分析是指根据单词的不同形态和变化形式来进行词汇分析的过程。在语言学中，词形分析涉及到词的词根、词干、前缀、后缀、派生词等部分的分析，帮助我们理解单词的构成、变化和意义。通过词形分析，可以更深入地了解单词的形态学特征和变化规律，从而帮助我们更好地掌握和运用语言。

词形还原

对于某些语言（特别是土耳其语、阿拉伯语等黏着语系的语言）枚举所有词的词形变换则是不可能的

例如：土耳其语词汇 uygarlaştıramadıklarımızdanmışsınızcasına 是由以下 10 项变换组合而成[45]：

uygar	+la	+tr	+ama	+dk	+lar	+mz	+dan	+m	+snz	+casna
civilized	+BEC	+CAUS	+NABL	+PART	+PL	+P1PL	+ABL	+PAST	+2PL	+AsIf

+BEC	“变成”(become)
+CAUS	标识使役动词
+NABL	“不能” (not able)
+PART	过去分词
+PL	名词复数
+P1PL	第一人称复数所有格
+ABL	表来源的离格 (ablative (from/among) case maker)
+PAST	带过去时的间接引语 (indirect/inferential past)
+AsIf	从限定动词 (finite verb) 派生出的副词

词干提取

词干提取 (Stemming）是词形分析的简化版本，其目标是将具有词形变化（通常是屈折或派生）的词语还原为其词干（Word Stem）

与词形分析不同，词干提取并不要求还原的词干一定与其语言学词根完全一致，只需要将相关的单词映射为统一的词干。

例如：词干提取算法 Porter Stemmer
argue, argued, argues, arguing, 以及 argus 都转换为 argu.

词干提取

最简单的词干提取算法可以通过查询词表的方法获得

另外一种方法是**后缀剥离**（Suffix-stripping），通过定义一组规则，将特定的后缀从词形中删除

例如：

如果单词以ed 结尾，则删除ed
如果单词以ing 结尾，则删除ing
如果单词以ly结尾，则删除ly

但是无法处理特殊变形（如：ran，took 等）

词干提取

后缀替代（Suffix Substitution）算法将单词后缀替换为另外一个后缀。

例如：

如果单词以’ational’ 结尾，则替换为’ate’（relational → relate）
如果单词以’ing’ 结尾，则替换为’ε’（working → work）
如果单词以’zzes’ 结尾，则替换为’Z’（quizzes → quiz）

为什么分词

Natural language processing (NLP) is a subfield of linguistics, computer science, and artificial intelligence concerned with the interactions between computers and human language, in particular how to program computers to process and analyze large amounts of natural language data.

自然语言处理是语言学、计算机科学和人工智能的一个分支，研究计算机与人类语言之间的相互作用，尤其是如何编程计算机来处理和分析大量的自然语言数据。

为什么分词

- 在语言学上，词语的定义是具备独立意义的最小单位。
- 汉语文本是基于单字的，汉语的书面表达方式也是以汉字作为最小单位的，词与词之间没有显性的界限标志，因此分词是汉语文本分析处理中首先要解决的问题。
- 添加合适的显性的词语边界标志使得所形成的词串反映句子的本意，这个过程就是**分词**

坚定不移/反对/腐败

分词面临的主要难题

- 如何面向大规模开放应用是汉语分词研究解决的主要问题
  - 如何识别未登录词
  - 词语边界歧义处理
  - 实时性应用中的效率问题

分词面临的主要难题

中文分词面临着词语切分歧义、新词发现等诸多挑战，这正是中文语言复杂性和丰富性的体现。解决这些“中文问题”，离不开中国科研工作者的自主创新和不懈努力。每一次算法的改进，都为提升中文信息处理能力贡献了力量，是构建**国家科技实力**和**文化软实力**的重要基石。这激发学生面对困难，勇于探索的**创新精神**。

分词歧义——交集型切分歧义

- 汉字串AJB被称作交集型切分歧义，如果满足AJ、JB同时为词(A、J、B分别为汉字串)。此时汉字串J被称作交集串。
  - [例] “结合成分子”
    - 结合 | 成分 | 子
    - 结合 | 成 | 分子
    - 结 | 合成 | 分子
  - [例] “美国会通过对台售武法案”
  - [例] “乒乓球拍卖完了”

分词歧义——失之毫厘，谬以千里

- [例] “发展中国家”应该如何切分？
  - 发展中| 国家 |
  - 发展 | 中国 | 家
- Q1:这两种不同的切分，对机器后续的语义理解会产生什么影响？
- Q2:如果一个法律文书分析系统或一个新闻情感判断系统在这里切错了，可能会造成什么严重的后果？

分词歧义——组合型切分歧义

- 汉字串AB被称作组合型切分歧义，如果满足条件：A、B、AB同时为词

  [例]组合型切分歧义：“起身”

  - 他站 | 起 | 身 | 来。
  - 他明天 | 起身 | 去北京。

分词歧义——真歧义

真歧义是指如果汉字串 ABC 满足多种切分方式下语法和语义均没有问题, 只有**通过上下文环境**才能给出正确的切分结果，则汉字串 ABC 被称为真歧义。

例如：白天鹅在水里游泳。

切分方式 1：白天 | 鹅 | 在 | 水 | 里 | 游泳 | 。

切分方式 2：白天鹅 | 在 | 水 | 里 | 游泳 | 。

未登录词

- 虽然一般的词典都能覆盖大多数的词语，但有相当一部分的词语不可能穷尽地收入系统词典中，这些词语称为未登录词或新词
- 分类：
  - 专有名词：中文人名、地名、机构名称、外国译名、时间词
  - 重叠词：“高高兴兴”、“研究研究”
  - 派生词：“*一次性*用品”
  - 与领域相关的术语：“互联网”

宗成庆教授在新闻领域的语料也进行了分词错误分析，结果发现未登录词造成的分词错误超过**98%**

拥抱时代脉搏——“让算法与时俱进”

近年的网络热词（如“yyds” “卷王”）让现有分词工具测试时，多数基于传统词典匹配的分词工具立刻陷入 “无措”。这种错误体现了传统分词对 “网络缩写无明确字符边界” 特性的适配不足，既无法通过字符组合规律判断整体性，也缺乏对流行语境的动态感知。

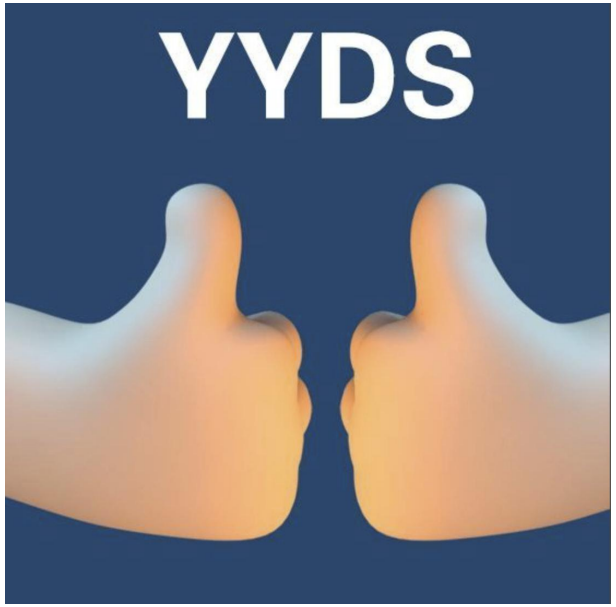

拥抱时代脉搏——“让算法与时俱进”

Q1:为什么强大的分词算法会不认识这些词?

Q2:一个不能识别新词的NLP系统，对于一个快速发展的社会来说，意味着什么?

具体的分词标准实例

- 《信息处理用现代汉语分词规范及自动分词方法》：结合紧密、使用频繁
- 二字或三字词，以及结合紧密、使用稳定的：发展 可爱 红旗 对不起 自行车 青霉素
- 四字成语一律为分词单位：胸有成竹　欣欣向荣

  四字词或结合紧密、使用稳定的四字词组:社会主义 春夏秋冬 由此可见
- 五字和五字以上的谚语、格言等，分开后如不违背原有组合的意义，应予切分：
  - 时间/就/是/生命/
  - 失败/是/成功/之/母

具体的分词标准实例

- 结合紧密、使用稳定的词组则不予切分:不管三七二十一
- 惯用语和有转义的词或词组，在转义的语言环境下，一律为分词单位:

  妇女能顶/半边天

  他真小气，象个/铁公鸡
- 略语一律为分词单位：科技 奥运会 工农业
- 分词单位加形成儿化音的“儿” ：花儿 悄悄儿 玩儿

具体的分词标准实例

- 阿拉伯数字等，仍保留原有形式:1234 7890
- 现代汉语中其它语言的汉字音译外来词，不予切分：巧克力 吉普
- 不同的语言环境中的同形异构现象，按照具体语言环境的语义进行切分:
  - 把 / 手 / 抬起来
  - 这个 / 把手 / 是木制的

常见的动词分词规范

- 动词前的否定副词一律单独切分: 不/写 不/能 没/研究 未/完成
- 用肯定加否定的形式表示疑问的动词词组一律切分，不完整的则不予切分: 说/没/说 看/不/看 相信/不/相信
- 动宾结构的词或结合紧密、使用稳定的: 开会 跳舞 解决/吃饭/问题 孩子该/念书/了
- 结合不紧密或有众多与之相同结构词组的动宾词组一律切分: 吃/鱼 学/滑冰 写/信

常见的动词分词规范

- 动宾结构的词或词组如中间插入其它成分，则应予切分: 吃/两/顿/饭 跳/新疆/舞
- 动补结构的二字词或结合紧密、使用稳定的二字动补词组，不予切分: 打倒 提高 加长 做好
- “2十1”或“1十2”结构的动补词组一律切分: 整理/好 说/清楚 解释/清楚 打/得/倒 提/不/高
- 偏正结构的词，以及结合紧密的词不予切分: 胡闹 瞎说 死记

常见的动词分词规范

- 复合趋向动词一律为分词单位: 出去 进来

  当插入“得、不”时应予切分: 出/得/去 进/不/来

- 动词与趋向动词结合的词组一律切分: 寄/来 跑/出去

- 多字动词无连词并列，一律切分: 调查/研究 宣传/鼓动

词的性质——齐夫定律

- 一个单词的词频与它的词频排名成反比
- 齐夫定律可以用数学表达式来表示：如果一个词的出现频次为 f，其在频率表中的排名为 r，则有 fr=C（其中 C 是常数）。

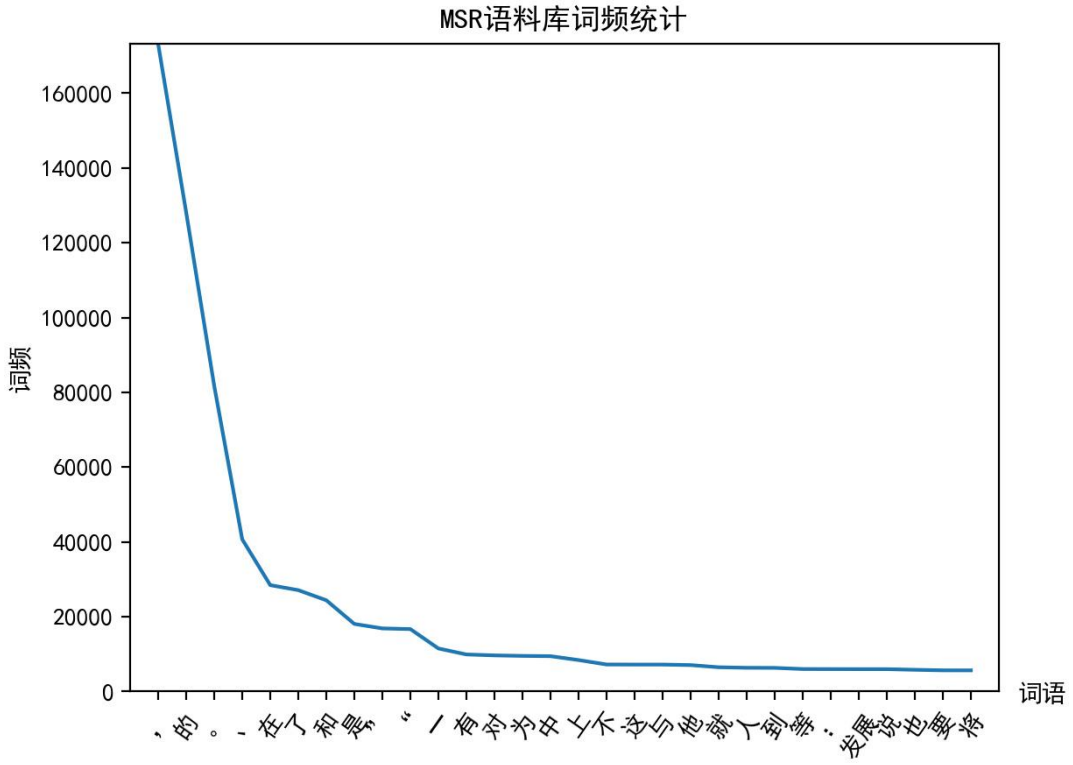

主要的分词方法

- 简单的模式匹配：按照一定的策略将待分析的汉字串与一个充分大的词典中的词条进行匹配，若在词典中找到某个字符串，则匹配成功
  - 正向最大匹配
  - 逆向最大匹配
  - 双向最大匹配
- 基于统计的方法：
  - 语言模型
  - 序列标注
    - 隐马尔可夫模型、
    - 条件随机场（CRF）

序列标注

将分词过程转换为**对字的分类**问题

- 对于输入句子中的每一个字 c_i，根据它在分词结果中的位置赋予不同的标签

  开始（B）、中间（I）、结尾（E）以及单独成词（S）

例如：

输入句子：他是研究生物化学的一位科学家。

分词结果：他 | 是 | 研究 | 生物化学 | 的 | 一 | 位 | 科学家 |。

对应标记：他/S 是/S 研/B 究/E 生/B 物/I 化/I 学/E 的/S 一/B 位/E 科/B 学/I 家/E 。/S

词典

- 搜狗实验室发布的互联网词库（SogouW，其中有15万个词条）
- 清华大学开放中文词库（THUOCL）
- 码农场千万级巨型汉语词库（千万级词条）

完全切分

- **完全切分**指的是，找出一段文本中的所有单词，不是标准意义上的分词

```
def fully_segment(text, dic):
    word_list = []
    for i in range(len(text)):    # i从0遍历到text的最后一个字的下标
        for j in range(i + 1, len(text) + 1):   # j遍历[i + 1, len(text)]区间
            word = text[i:j]      # 取出连续区间[i, j)对应的字符串
            if word in dic:       # 如果在词典中，则认为是一个词
                word_list.append(word)
    return word_list
```

正向最长匹配

```
def forward_segment(text, dic):
    word_list = []
    i = 0
    while i < len(text):
        longest_word = text[i]                  # 当前扫描位置的单字
        for j in range(i + 1, len(text) + 1): # 所有可能的结尾
            word = text[i:j]                    # 从当前位置到结尾的连续字符串
            if word in dic:                     # 在词典中
                if len(word) > len(longest_word):   # 并且更长
                    longest_word = word             # 则更优先输出
        word_list.append(longest_word)              # 输出最长词
        i += len(longest_word)                      # 正向扫描
    return word_list
```

逆向最长匹配

找出与正向匹配的区别

```
def backward_segment(text, dic):
    word_list = []
    i = len(text) - 1
    while i >= 0:                                   # 扫描位置作为终点
        longest_word = text[i]                      # 扫描位置的单字
        for j in range(0, i):                       # 遍历[0, i]区间作为待查询词语的起点
            word = text[j: i + 1]                   # 取出[j, i]区间作为待查询单词
            if word in dic:
                if len(word) > len(longest_word):   # 越长优先级越高
                    longest_word = word

                    break
        word_list.insert(0, longest_word)           # 逆向扫描，因此越先查出的单词在位置
                                                     上越靠后
        i -= len(longest_word)
    return word_list
```

两种最长匹配方法比较

序号	原文	正向最长匹配	逆向最长匹配
1	项目的研究	**[项目, 的, 研究]**	[项, 目的, 研究]
2	商品和服务	[商品, 和服务]	[商品, 和服务]
3	研究生命起源	[研究生, 命, 起源]	**[研究, 生命, 起源]**
4	当下雨天地面积水	[当下, 雨天, 地面, 积水]	**[当, 下雨天, 地面, 积水]**
5	结婚的和尚未结婚的	[结婚, 的, 和尚, 未, 结婚, 的]	**[结婚, 的, 和, 尚未, 结婚, 的]**
6	欢迎新老师生前来就餐	[欢迎新, 老师, 生前, 来, 就餐]	**[欢迎, 新老, 师生, 前来, 就餐]**

双向最长匹配

一种融合两种匹配方法的复杂规则集，流程如下。

- 同时执行正向和逆向最长匹配，若两者的词数不同，则返回词数更少的那一个。
- 否则，返回两者中单字更少的那一个。当单字数也相同时，优先返回逆向最长匹配的结果。

双向最长匹配

```
def count_single_char(word_list: list):  # 统计单字成词的个数
    return sum(1 for word in word_list if len(word) == 1)


def bidirectional_segment(text, dic):
    f = forward_segment(text, dic)
    b = backward_segment(text, dic)
    if len(f) < len(b):                          # 词数更少优先级更高
        return f
    elif len(f) > len(b):
        return b
    else:
        if count_single_char(f) < count_single_char(b):  # 单字更少优先级更高
            return f
        else:
            return b                                     # 都相等时逆向匹配优先级更高
```

最长匹配

序号	原文	正向最长匹配	逆向最长匹配	双向最长匹配
1	项目的研究	**[项目, 的, 研究]**	[项, 目的, 研究]	[项, 目的, 研究]
2	商品和服务	[商品, 和服务]	[商品, 和服务]	[商品, 和服务]
3	研究生命起源	[研究生, 命, 起源]	**[研究, 生命, 起源]**	**[研究, 生命, 起源]**
4	当下雨天地面积水	[当下, 雨天, 地面, 积水]	**[当, 下雨天, 地面, 积水]**	[当下, 雨天, 地面, 积水]
5	结婚的和尚未结婚的	[结婚, 的, 和尚, 未, 结婚, 的]	**[结婚, 的, 和, 尚未, 结婚, 的]**	**[结婚, 的, 和, 尚未, 结婚, 的]**
6	欢迎新老师生前来就餐	[欢迎新, 老师, 生前, 来, 就餐]	**[欢迎, 新老, 师生, 前来, 就餐]**	**[欢迎, 新老, 师生, 前来, 就餐]**

速度评测

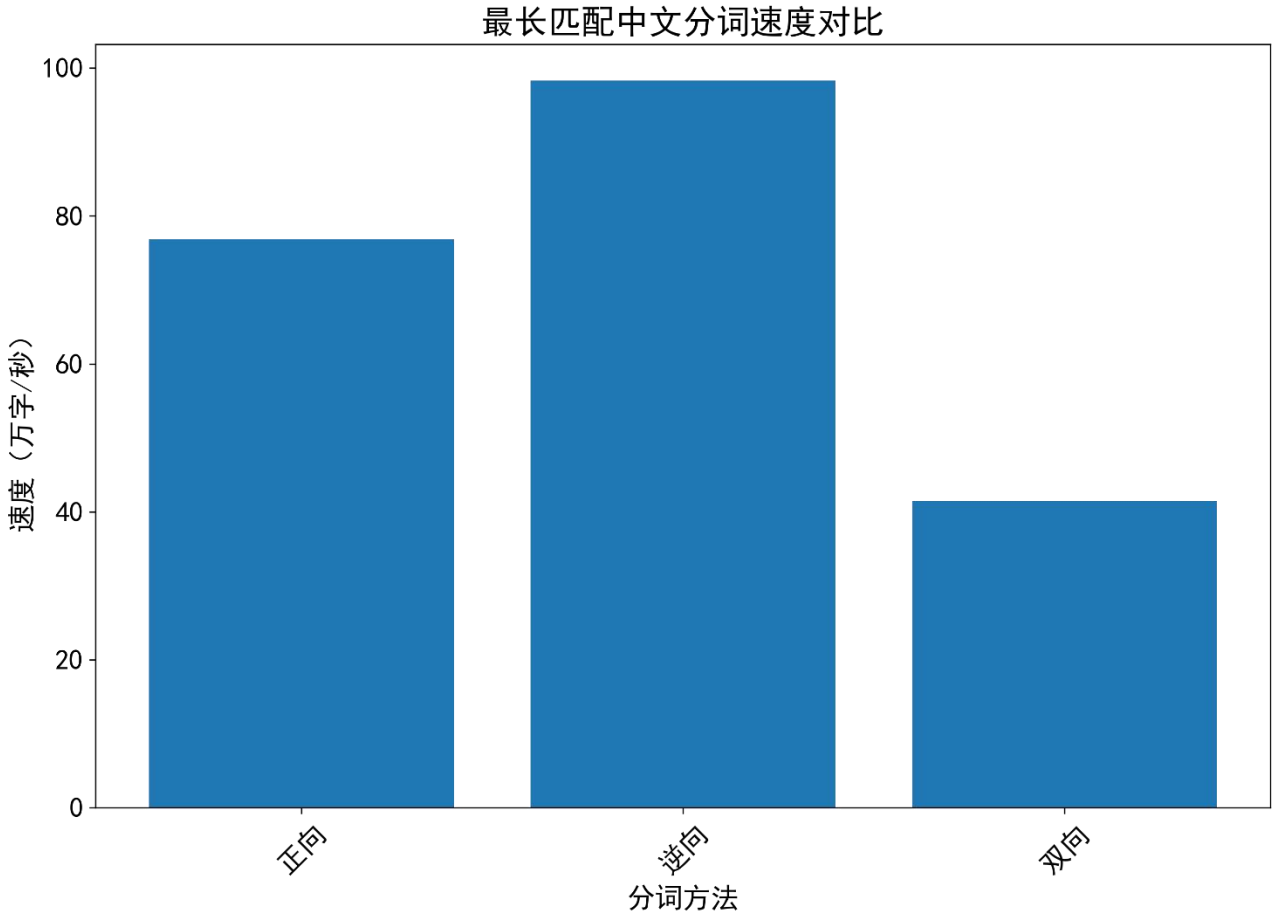

几种最大匹配算法在中文分词中的作用占比

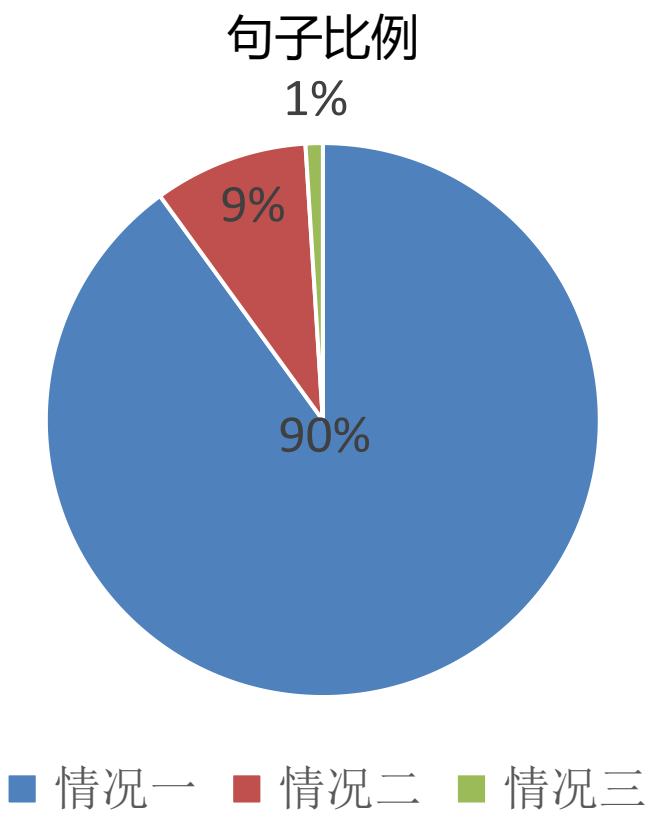

据SunM.S. 和 Benjamin K.T.（1995）的研究表明，中文中90.0%左右的句子，正向最大匹配法和逆向最大匹配法完全重合且正确，只有大概9.0%的句子两种切分方法得到的结果不一样，但其中必有一个是正确的（歧义检测成功），只有不到1.0%的句子，或者正向最大匹配法和逆向最大匹配法的切分虽重合却是错的，或者正向最大匹配法和逆向最大匹配法切分不同但两个都不对（歧义检测失败）。这正是双向最大匹配法在实用中文信息处理系统中得以广泛使用的原因所在。

字典树

- 如何以一种速度快，省内存的方式判断集合（词典）中是否含有字符串。

Trie

- A tree representing a set of strings.

{
aeef
ad
bbfe
bbfg
c
}

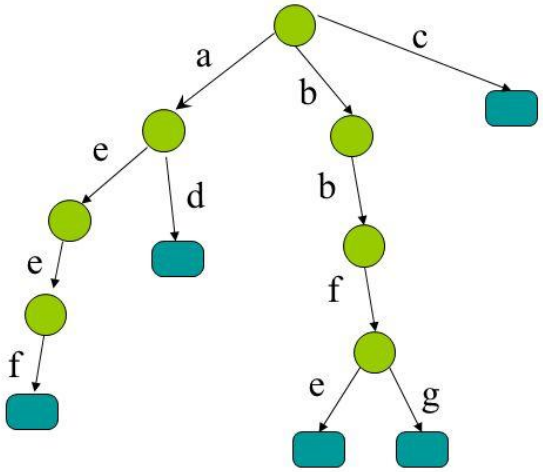

什么是字典树

- 字典树中每条边都对应一个字
- 从根节点往下的路径构成一个个字符串
- 在终点节点做标记表示该节点对应词语的结尾

词语	路径
入门	0-1-2
自然	0-3-4
自然人	0-3-4-5
自然语言	0-3-4-6-7
自语	0-3-8

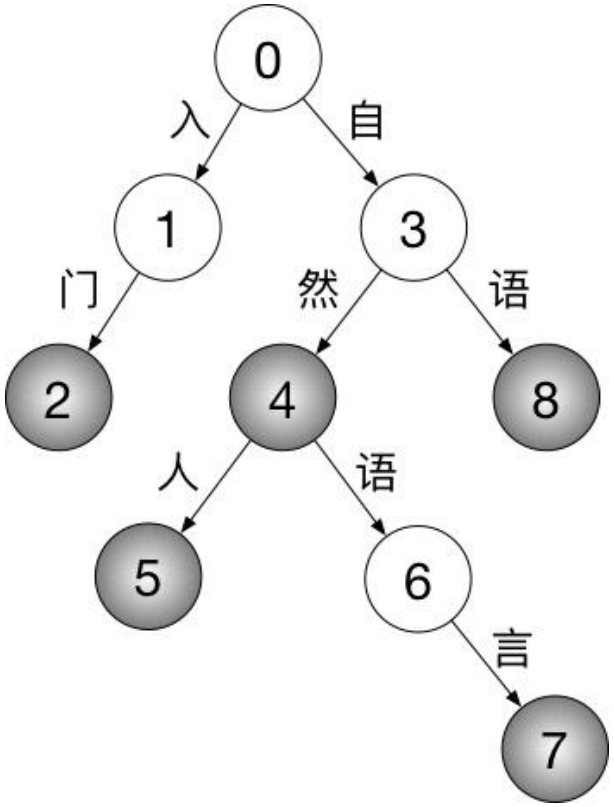

准确率

- 准确率（accuracy）是用来衡量一个系统的准确程度（accurate）的值，可以理解为一系列评测指标，在不同的NLP任务中，采用不同的评价指标。

准确率

分词效果的优劣直接影响后续所有中文自然语言处理任务的性能。这要求我们在算法设计和实现中，展现出精益求精的工匠精神。无论是词典的构建、歧义的处理，还是统计模型的训练，都需要细致入微的观察和反复的试验。这种追求卓越、不断优化的过程，也正是**数据驱动**和**实证精神**的体现，强调了**从实践中获取真知**。

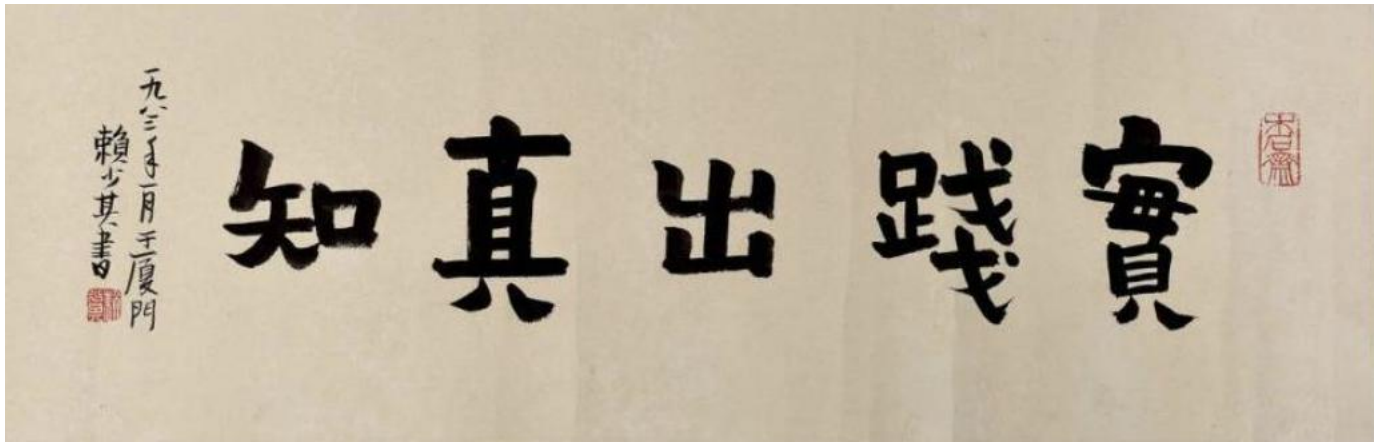

混淆矩阵与TP/FN/FP/TN

1. TP（true positive，真阳）：预测是P，答案果然是真的P。
2. FP（false positive，假阳）：预测是P，答案是N，因此是假的P。
3. TN（true negative，真阴）：预测是N，答案果然是真的N。
4. FN（false negative，假阴）：预测是N，答案是P，因此是假的N。

答案 / 预测	P	N
P	TP	FP
N	FN	TN

混淆矩阵与TP/FN/FP/TN

- 样本全集 =TP ∪ FP ∪ FN ∪ TN
- 它们没有交集

答案 / 预测	P	N
P	TP	FP
N	FN	TN

精确率

- 精确率（precision，简称P值）指的是预测结果中正类数量占全部正类结果的比率

$$Precision = \frac{TP}{TP + FP}$$

- 在所有正类样本中，能回想起的正类的比例就是**召回率**

$$Sensitivity = Recall = \frac{TP}{TP + FN}$$

- $F_1 - Score$

$$F_1\ Score = \frac{2 * Precision * Recall}{Precision + Recall}$$

中文分词中的P、R、F1计算

- 标准答案的所有区间构成一个集合A，作为正类
  - 此集合之外的所有区间构成另一个集合（A的补集A^C），作为负类
- 记分词结果所有单词区间构成集合B

$$TP \cup FN = A$$
$$TP \cup FP = B$$

$$TP = A \cap B$$

$$P = \frac{|A \cap B|}{|B|}$$
$$R = \frac{|A \cap B|}{|A|}$$

中文分词中的P、R、F1计算

	单词序列	集合	集合中的元素
标准答案	结婚 的 和 尚未 结婚 的	A	$[0,2], [2,3], [3,4], [4,6], [6,8], [8,9]$
分词结果	结婚 的 和尚 未结婚 的	B	$[0,2], [2,3], [3,5], [5,8], [8,9]$
重合部分	结婚 的 和尚未结婚 的	$A \cap B$	$[0,2], [2,3], [8,9]$

分词“准确率”为：

$$P = \frac{3}{5} = 60\%$$

$$R = \frac{3}{6} = 50\%$$

$$F_1 = \frac{2 \times 60\% \times 50\%}{60\% + 50\%} = 55\%$$

中文分词技术

分词技术不仅仅服务于冰冷的机器，最终目的是为了更好地理解和服务人类语言。例如，通过提升分词准确率，可以改善机器翻译、智能问答等应用的用户体验，惠及更广泛的人群。这启发我们思考技术发展的**人文关怀**，以及如何让先进技术更好地服务社会，促进**信息共享**和**知识普及**，体现**技术向善**的理念。

第二届国际中文分词评测

- http://sighan.cs.uchicago.edu/bakeoff2005/
- MSR语料
  - 词典位于corpus_data/第二届国际中文分词评测/icwb2-data/training/msr_training.utf8
  - 测试语料位于corpus_data/第二届国际中文分词评测/icwb2-data/testing/msr_test.utf8
  - 标准答案位于corpus_data/第二届国际中文分词评测/icwb2-data/gold/msr_test_gold.utf8

OOV Recall Rate与IV Recall Rate

- OOV指的是“**未登录词**” （out of vocabulary）
- IV指的是“**登录词**” （in vocabulary）
    - IV Recall Rate指的是词典中的词汇被正确召回的概率