/04

序列标注与隐马尔可夫模型

序列标注

命名实体识别

隐马尔科夫模型

序列标注问题

- **序列标注**（tagging）指的是给定一个序列$\boldsymbol{x} = x_1 x_2 \ldots x_n$，找出序列中每个元素对应标签$\boldsymbol{y} = y_1 y_2 \ldots y_n$的问题
- 其中，y所有可能的取值集合称为**标注集**（tagset）

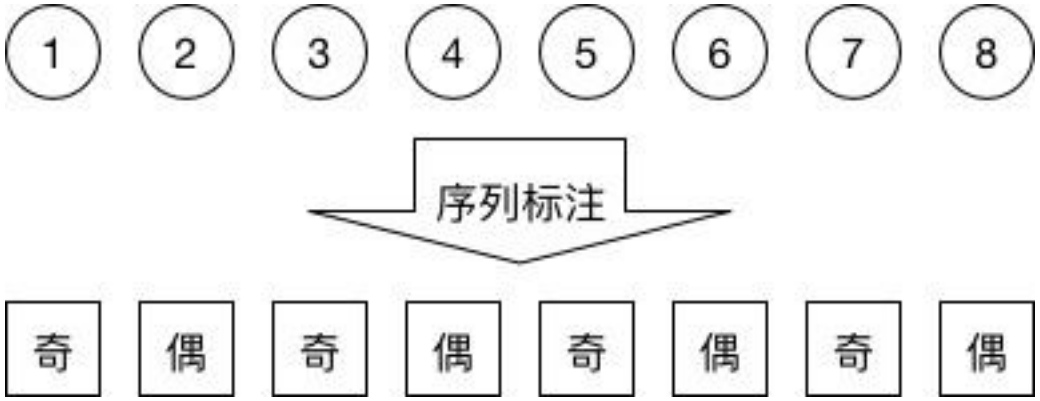

序列标注问题

在自然语言处理的学习中，我们要认识到数据标注是模型的基石，尤其在序列标注任务（如词性标注）中，标注的准确性与一致性直接决定模型的性能。采用“BIO”标注体系时，我们应当对每个标签的定义和边界划分一丝不苟，在反复实践中锻炼细致入微的思维与**严谨治学**的态度。我们要以**工匠精神**对待每一个技术细节，在不断打磨中追求卓越，成长为AI时代的“数字工匠”，用专业与责任为**科技强国**贡献力量。

序列标注与中文分词

- 中文分词转化为标注集为{切,过}的序列标注问题

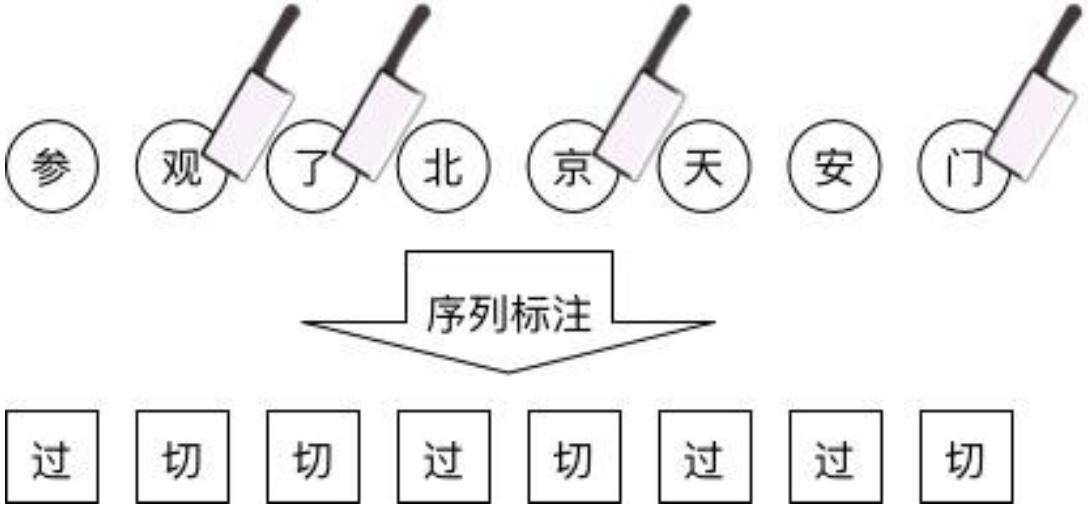

序列标注与中文分词

- 流行的标注集{B, M, E, S}
- 汉字分别作为词语首尾（**B**egin、**E**nd）、词中（**M**iddle）以及单字成词（**S**ingle）

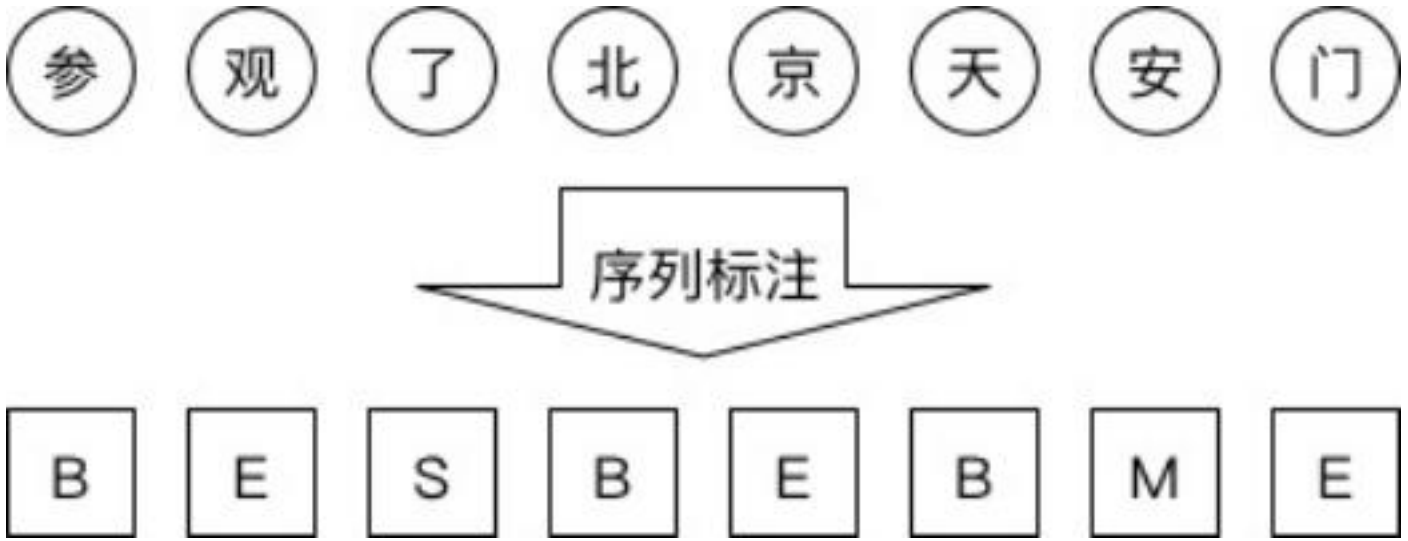

序列标注与词性标注

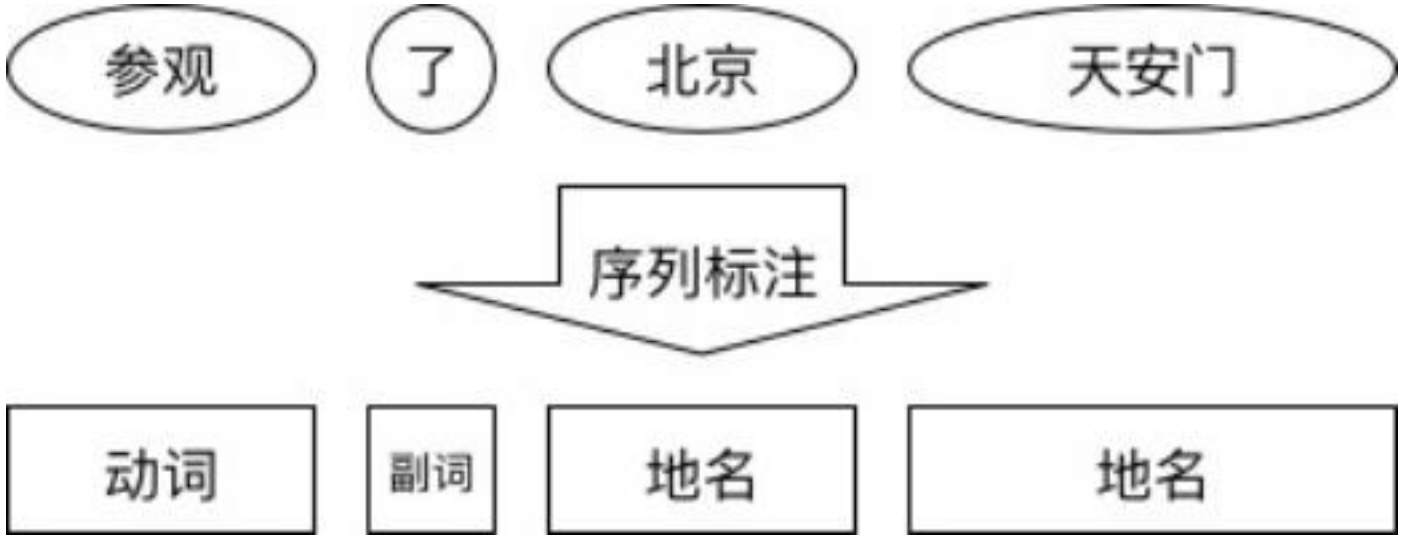

序列标注与命名实体识别

- 地名和机构名常常由多个单词组成（称为**复合词**）

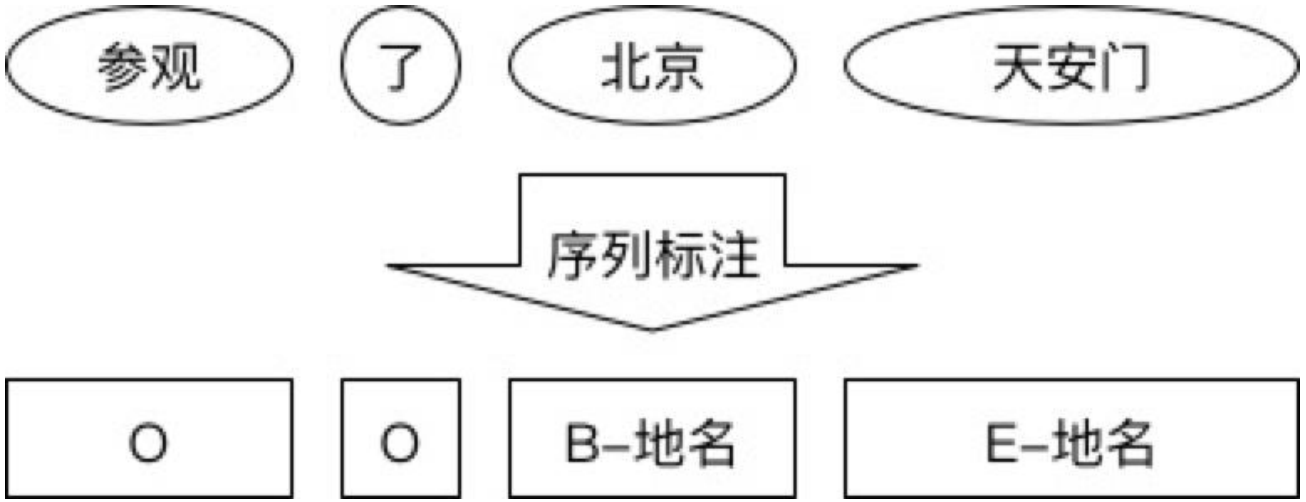

隐马尔可夫模型

- **隐马尔可夫模型**（Hidden Markov Model，HMM）是描述两个时序序列联合分布$p(\boldsymbol{x}, \boldsymbol{y})$的概率模型
  - $\boldsymbol{x}$序列外界可见（外界指的是观测者），称为**观测序列**（observation sequence）
    - 观测x为单词
  - $\boldsymbol{y}$序列外界不可见，称为**状态序列**（state sequence）
    - 状态y为词性
- 状态也被称为**隐状态**（hidden state），而观测被称为**显状态**（visible state）
- **隐马尔可夫模型**之所以称为“马尔可夫模型”，是因为它满足马尔可夫假设

隐马尔可夫模型

- HMM的训练过程，凝聚了数据采集、精确标注与算法优化的集体智慧。它告诉我们，科技的进步离不开每一位参与者的努力，唯有**协作共进**，融入**集体价值观**才能实现系统的高效与卓越。前向算法通过计算所有可能路径的总概率，启示我们在学习与科研中要具备**全局思维**与前瞻意识。只有全面审视多种可能，才能在复杂环境中找到通向成功的最优方向。

从马尔可夫假设到隐马尔可夫模型

- 隐马尔可夫模型的两个基本假设
  - **齐次马尔可夫假设**：假设隐藏的马尔可夫链在任一时刻 t 的状态只依赖于其前一个时刻的状态：

$$p(y_t|y_{t-1},\ x_{t-1},\cdots,y_1,\ x_1)\ =\ p(y_t|y_{t-1}),\ i=1,\ 2,\ \ldots,\ T$$

  - **观测独立性假设**：假设任意时刻的观测 x_t只依赖于该时刻的状态y_t，与其他的观测及状态都无关。

$$p(x_t|y_T,\ x_T,\ y_{T-1},\ x_{T-1},\cdots,y_{t+1},\ x_{t+1},\ \cdots,\ y_1,\ x_1)\ =\ p(x_t|y_t)$$

从马尔可夫假设到隐马尔可夫模型

- 用箭头表示事件的依赖关系（箭头终点是结果，依赖于起点的因缘）

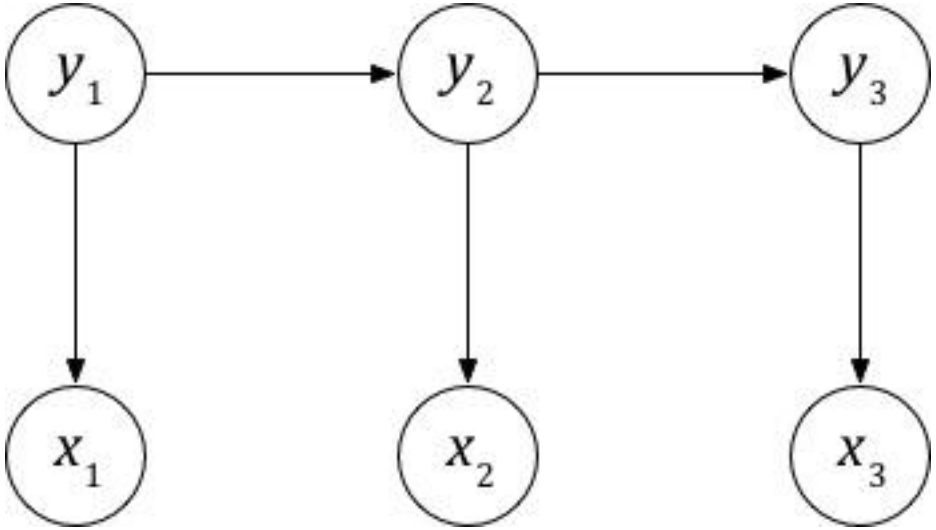

隐马尔可夫模型状态序列与观测序列的依赖关系

从马尔可夫假设到隐马尔可夫模型

- **隐马尔可夫模型**利用三个要素来模拟时序序列的发生过程
  - 初始状态概率向量
  - 状态转移概率矩阵
  - 发射概率矩阵（也称作观测概率矩阵）

初始状态概率向量

- 系统启动时进入的第一个状态y_1称为**初始状态**
  - 假设y有N种可能的取值，即$y \in \{s_1, \cdots, s_N\}$，那么$y_1$就是一个独立的离散型随机变量，由$p(y_1|\boldsymbol{\pi})$描述
  - 其中$\boldsymbol{\pi} = (\pi_1, \cdots, \pi_N)^{\mathrm{T}}, 0 \leq \pi_i \leq 1, \sum_{i=1}^{N} \pi_i = 1$ 是概率分布的参数向量，称为**初始状态概率向量**

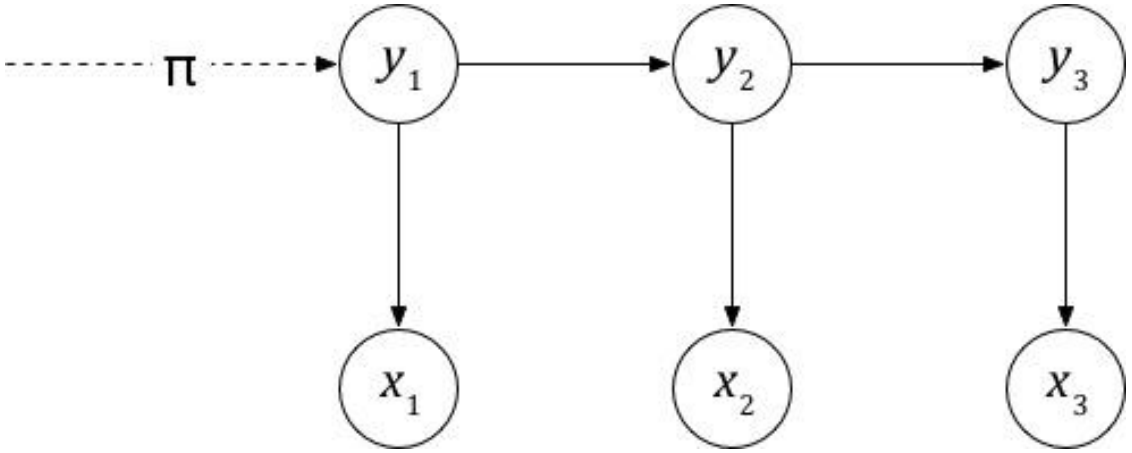

隐马尔可夫模型中的初始状态概率向量

初始状态概率向量

- **例如**

$$
\begin{aligned}
p(y_1 = \mathrm{B}) &= 0.7 \\
p(y_1 = \mathrm{M}) &= 0 \\
p(y_1 = \mathrm{E}) &= 0 \\
p(y_1 = \mathrm{S}) &= 0.3
\end{aligned}
\tag{1}
$$

此时**隐马尔可夫模型**的初始状态概率向量为$\boldsymbol{\pi} = [0.7,0,0,0.3]$

状态转移概率矩阵

- 从状态s_i到状态s_j的概率就构成了一个$N \times N$的方阵，称为**状态转移概率矩阵$\boldsymbol{A}$**：

$$\boldsymbol{A} = [p(y_{t+1} = s_j | y_t = s_i)]_{N \times N}$$

- 其中下标i、j分别表示状态的第i、j种取值，比如我们约定1表示标注集中的B，依序类推。

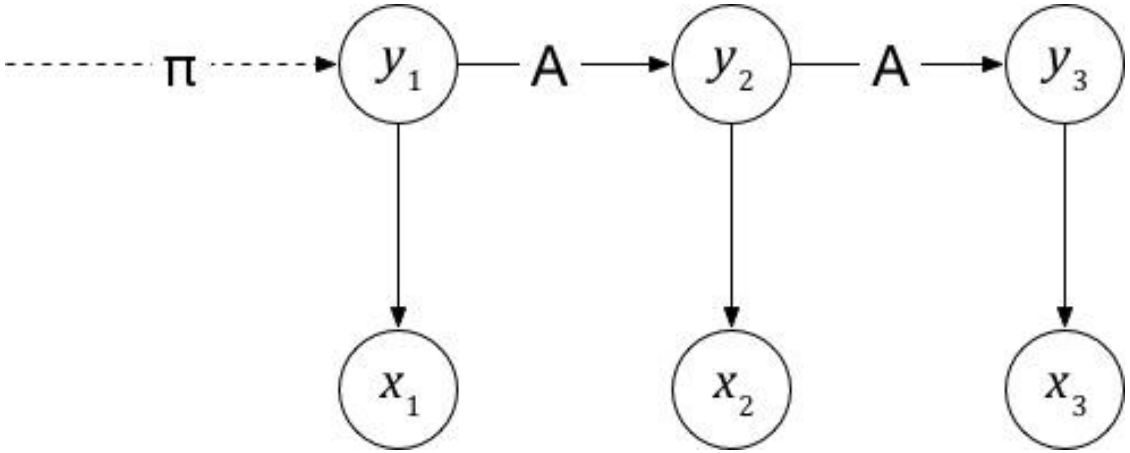

发射概率矩阵

- 给定每种y，x都是一个独立的离散型随机变量，其参数对应一个向量
- 这些参数向量构成了$N \times M$的矩阵，称为**发射概率矩阵$\boldsymbol{B}$**。

$$\boldsymbol{B} = [p(x_t = o_i | y_t = s_j)]_{N \times M}$$

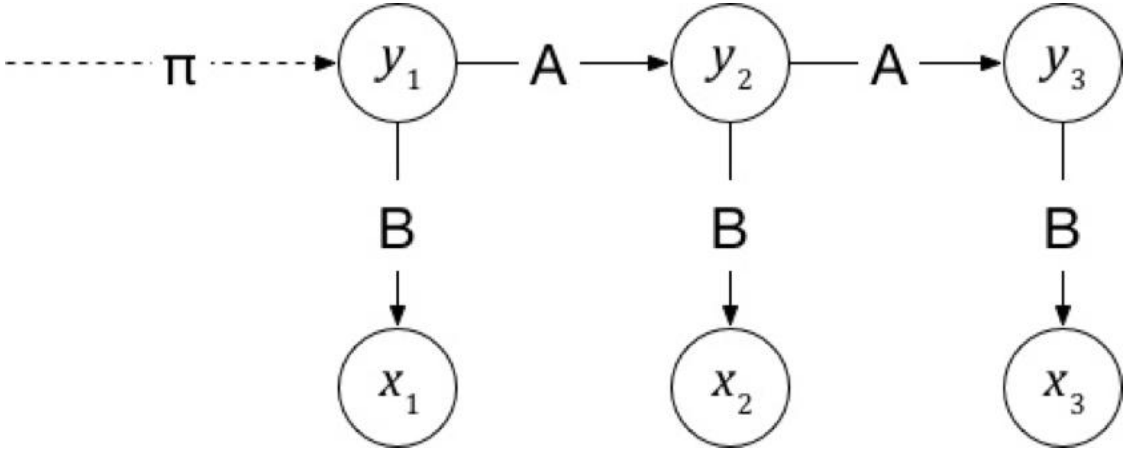

隐马尔可夫模型的三个主要问题

为了简化起见，隐马尔可夫模型可以表示成 $\lambda = (A, B, \pi)$ 。 M, N也隐含地已经包含在 A, B, π中。隐马尔可夫模型的三个主要问题是：

问题1：观测概率计算 在给定模型 $\lambda = (A, B, \pi)$的情况下，如何根据观测序列 $O = \{o_1, o_2, \ldots, o_T\}$计算 $P(O|\lambda)$ ，即在给定模型情况下，如何计算观测序列的概率。

问题2：状态序列预测 在给定模型 $\lambda = (A, B, \pi)$和观测序列 $O = \{o_1, o_2, \ldots, o_T\}$ 的情况下，如何得到与该观测序列最匹配的状态序列 $Q = \{q_1, q_2, \ldots, q_T\}$ ，即如何根据观测序列推断出隐藏的状态序列。

问题 3：模型参数学习 在给定观测序列 $O = \{o_1, o_2, \ldots, o_T\}$ 情况下，如何调整模型参数 $\lambda = (A, B, \pi)$使得该序列的 $P(O|\lambda)$最大，即如何训练模型使其能最好地建模观测序列。

案例分析--“三问定乾坤”

我们将HMM的三个问题想象成一个生动的“盲人摸象”

HMM三大问题	比喻情境	核心问题	目标
1. 评估问题	盲人已经摸到一连串触感（如皮肤粗糙→长鼻→大耳→粗腿），想知道：“我摸到的这些触感，真的是大象的可能性大吗？”	计算在给定模型参数下，这组观测序列出现的概率	评估“观测结果”与模型的匹配程度
2. 解码问题	盲人只能通过触感推测：“我刚才摸到的部分，究竟是哪一部分的大象？”（鼻子？腿？耳朵？）	根据观测序列，寻找最可能的状态序列	猜测“隐藏状态”序列
3. 学习问题	盲人摸过很多次不同的大象，却不确定大象的结构规律，于是思考：“我能否根据摸到的感受，自己总结出‘大象的形状’？”	已知观测序列但未知模型参数，通过学习估计模型	学习模型参数，建立更准确的大象模型

案例分析--“三问定乾坤”

Q1:“这三个问题是不是覆盖了从‘认知’到‘推理’再到‘学习’的全过程？”

Q2:这种将一个复杂未知问题，拆解为几个定义清晰、可以求解的子问题的思路，对我们有什么启发?

隐马尔可夫模型的样本生成

- 某医院招标开发“智能”医疗诊断系统，用来辅助感冒诊断。已知
  - 来诊者只有两种状态：要么健康，要么发烧。
  - 来诊者不确定自己到底是哪种状态，只能回答感觉头晕、体寒或正常。医院认为，
  - 感冒这种病，只跟病人前一天的状态有关，并且，
  - 当天的病情决定当天的身体感觉。有位来诊者的病历卡上完整地记录了最近T天的身体感受（头晕、体寒或正常），请预测这T天的身体状态（健康或发烧）

案例——医疗诊断

- 感冒发病的规律

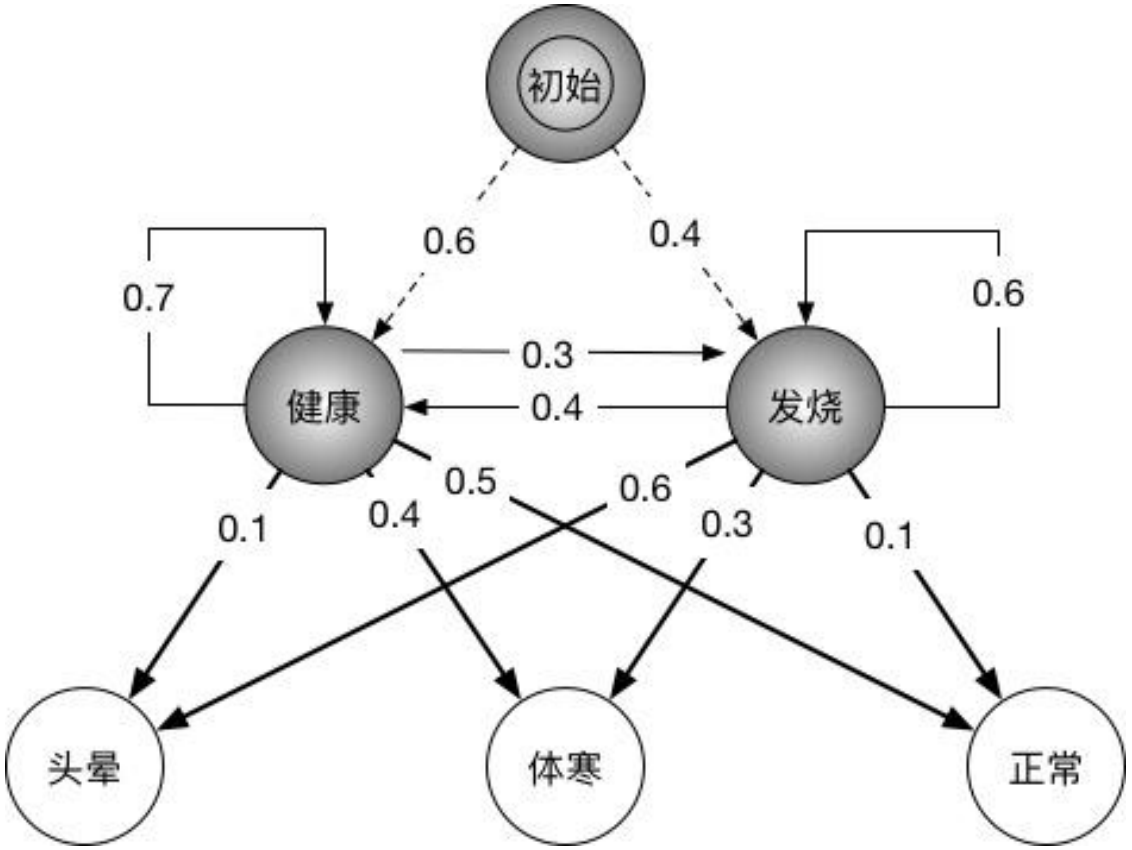

使用graphviz画流程图

- 安装graphviz
  - 安装文件下载地址：https://graphviz.gitlab.io/_pages/Download/Download_windows.html
  - 安装过程中选择将graphviz加到环境变量PATH
- 安装python插件graphviz： pip install graphviz
- 安装python插件pydotplus：pip install pydotplus

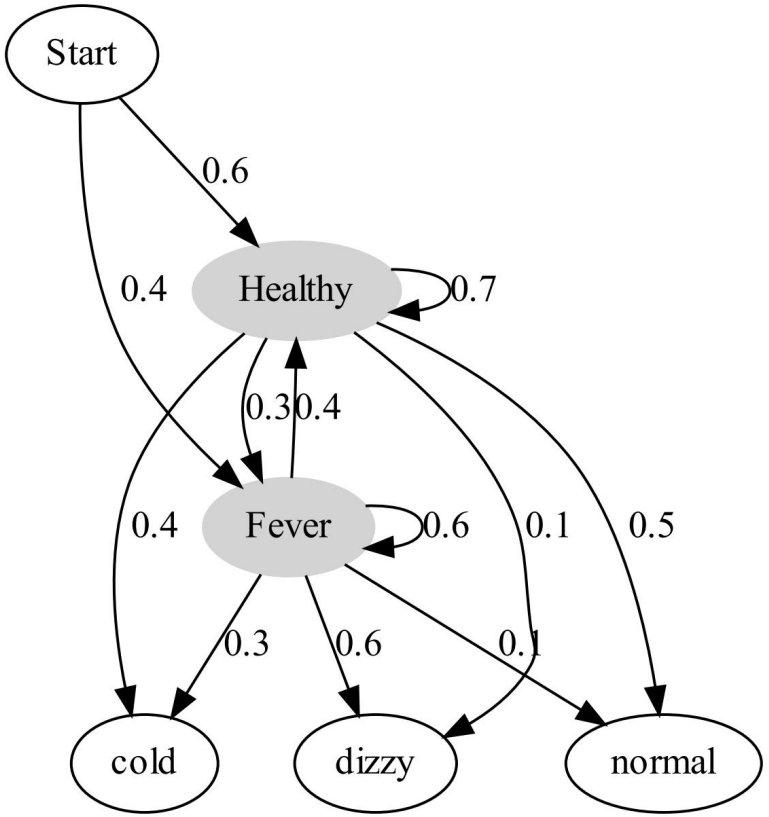

案例——医疗诊断

```
states = ('Healthy', 'Fever’)

start_probability = {'Healthy': 0.6, 'Fever': 0.4}

transition_probability = {'Healthy': {'Healthy': 0.7, 'Fever': 0.3},
                          'Fever': {'Healthy': 0.4, 'Fever': 0.6},}

emission_probability = {'Healthy': {'normal': 0.5, 'cold': 0.4, 'dizzy': 0.1},
                        'Fever': {'normal': 0.1, 'cold': 0.3, 'dizzy': 0.6}}

observations = ('normal', 'cold', 'dizzy')
```

样本生成算法

- 考虑长度为T的样本序列，它的生成过程就是沿着隐马尔可夫链走T步：

  ① 根据初始状态概率向量采样第一个时刻的状态$y_1 = s_i$，即$y_1 \sim \boldsymbol{\pi}$。

  ② y_t采样结束得到s_i后，根据状态转移概率矩阵第i行的概率向量 $\boldsymbol{A}_{i,:}$ 采样下一时刻的状态y_{t+1}，即$y_{t+1} \sim \boldsymbol{A}_{i,:}$。

  ③ 对每个$y_t = s_i$，根据发射概率矩阵的第i行$\boldsymbol{B}_{i,:}$采样x_t，即$x_t \sim \boldsymbol{B}_{i,:}$。

  ④ 重复步骤2共计$T-1$次，重复步骤3共计T次，输出序列$\boldsymbol{x}$与$\boldsymbol{y}$。

样本生成结果

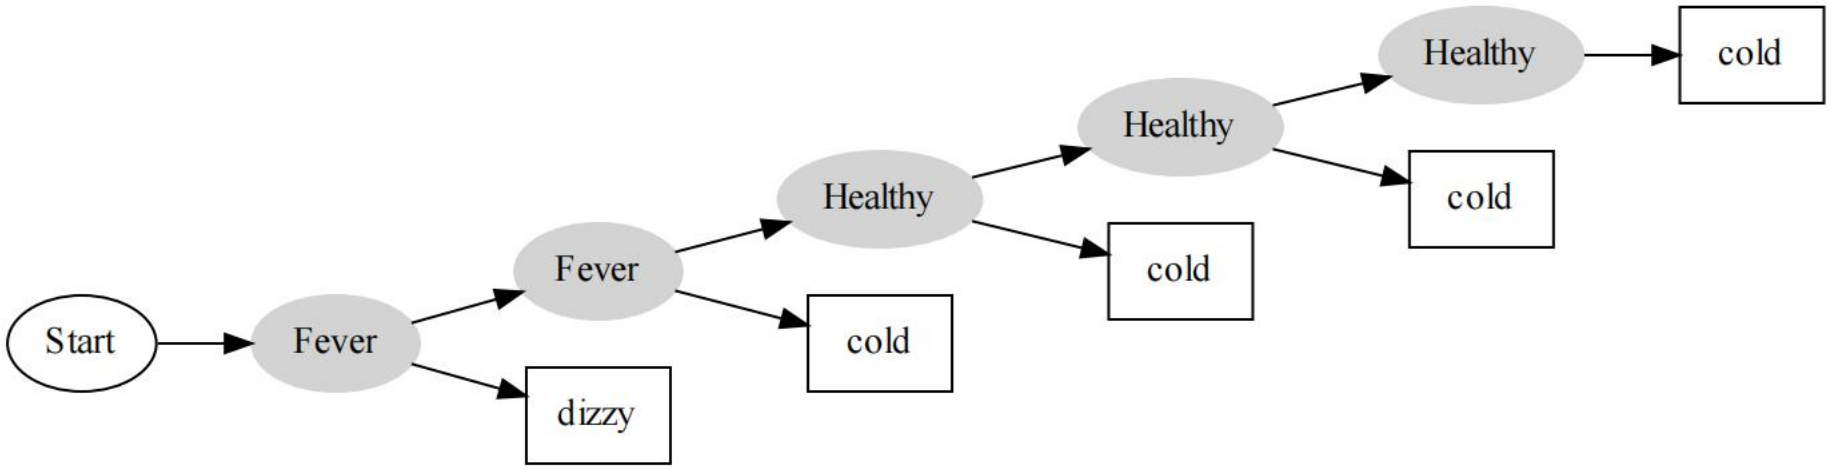
Start
Fever
Fever
dizzy
Healthy
cold
Healthy
cold
Healthy
cold
Healthy
cold

隐马尔可夫模型的训练

- 利用极大似然法来估计**隐马尔可夫模型**的参数
  - **隐马尔可夫模型**参数指的就是三元组$(\boldsymbol{\pi}, \boldsymbol{A}, \boldsymbol{B})$

转移概率矩阵的估计

- 记样本序列在时刻t处于状态s_i，时刻$t+1$转移到状态s_j
- 统计这样的转移频次计入矩阵元素$\boldsymbol{A}_{i,j}$
- 根据极大似然估计，从s_i到s_j的转移概率$a_{i,j}$可估计为矩阵第i行频次的归一化：

$$\hat{a}_{i,j} = \frac{\boldsymbol{A}_{i,j}}{\sum_{j=1}^{N} \boldsymbol{A}_{i,j}}, \quad i,j = 1,2,\cdots,N$$

```
transition_probability = {'Healthy': {'Healthy': 0.7, 'Fever': 0.3},
                          'Fever': {'Healthy': 0.4, 'Fever': 0.6},}
```

初始状态概率向量的估计

- 统计y_1的所有取值的频次记作向量$\boldsymbol{c}$，然后用类似的方法归一化：

$$\hat{\boldsymbol{\pi}}_i = \frac{\boldsymbol{c}_i}{\sum_{i=1}^{N} \boldsymbol{c}_i}, \quad i = 1,2,\cdots,N$$

```
start_probability = {'Healthy': 0.6, 'Fever': 0.4}
```

发射概率矩阵的估计

- 统计样本中状态为s_i且观测为o_j的频次，计入矩阵元素$\boldsymbol{B}_{i,j}$，则状态s_i发射观测o_j的概率估计为：

$$\hat{b}_{ij} = \frac{\boldsymbol{B}_{i,j}}{\sum_{j=1}^{M} \boldsymbol{B}_{i,j}}, \quad i = 1,2,\cdots,N; j = 1,2,\cdots,M$$

```
emission_probability = {'Healthy': {'normal': 0.5, 'cold': 0.4, 'dizzy': 0.1},
                        'Fever': {'normal': 0.1, 'cold': 0.3, 'dizzy': 0.6}}
```

隐马尔可夫模型的预测

- 在医疗诊断系统中，假定来了一位病人，他最近三天的身体感受是：正常、体寒、头晕，请预测他这三天最可能的健康状态和相应概率

概率计算的前向算法

- 顺着隐马尔可夫链走，首先$t = 1$时初始状态没有前驱状态，其发生概率由$\boldsymbol{\pi}$决定，即：

$$p(y_1 = s_i) = \boldsymbol{\pi}_i$$

- 接着对$t \geq 2$，状态y_t由前驱状态y_{t-1}转移而来，其转移概率由矩阵$\boldsymbol{A}$决定，即：

$$p(y_t = s_j | y_{t-1} = s_i) = \boldsymbol{A}_{i,j}$$

- 所以状态序列的概率为上面两式的乘积

$$p(\boldsymbol{y}) = p(y_1, y_2, \cdots, y_T) = p(y_1) \prod_{i=2}^{T} p(y_t | y_{t-1})$$

概率计算的前向算法

- 最后，对于每个$y_t = s_i$，都会“发射”一个$x_t = o_j$，其发射概率由矩阵$\boldsymbol{B}$决定，即：

$$p(x_t = o_j | y_t = s_i) = \boldsymbol{B}_{i,j}$$

- 那么给定长度为T的状态序列$\boldsymbol{y}$, 对应的$\boldsymbol{x}$的概率为

$$p(x|y) = \prod_{t=1}^{T} p(x_t|y_t)$$

- 观察和状态序列的联合概率

$$\begin{aligned} p(x, y) &= p(y)p(x|y) \\ &= p(y_1) \prod_{t=2}^{T} p(y_t|y_{t-1}) \prod_{t=1}^{T} p(x_t|y_t) \end{aligned}$$

搜索状态序列的维特比算法

- 所有备选状态构成一幅有向无环图，待求的概率最大的状态序列就是图中的最长路径

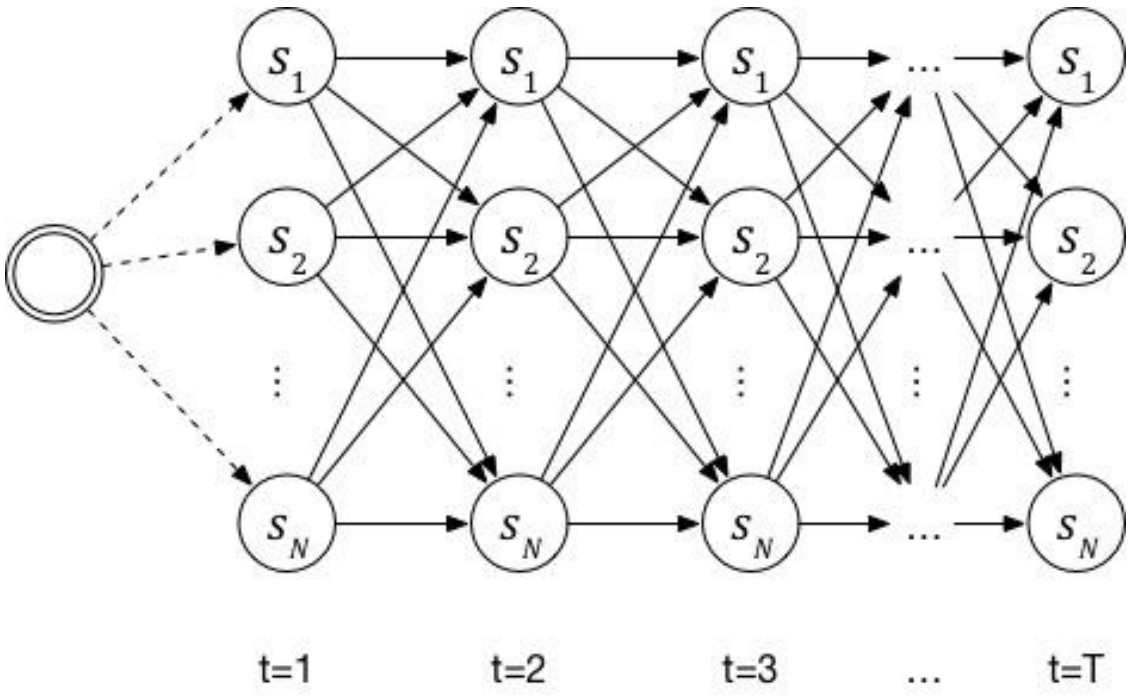

搜索状态序列的维特比算法

维特比算法实际是用动态规划解马尔可夫模型预测问题，用动态规划求解概率最大的路径。

- 定义时刻t状态为s_i的所有单个路径$(y_1,\ y_2,\ \ldots, s_i)$中概率的最大值：

$$\delta_t(s_i) = \max_{y_1, y_2, \ldots, y_{t-1}} P(y_t = s_i,\ y_{t-1}, \cdots, y_1, o_t, o_{t-1},\ \cdots,\ o_1), i = 1,\ 2,\ \ldots,\ N$$

- 由定义和隐马尔可夫假设可以得到变量δ的递推公式：

$$\delta_{t+1}\ (s_i) = \max_{y_1, y_2, \ldots, y_t} P(y_{t+1} = s_i,\ y_t, \cdots, y_1, o_{t+1}, o_t,\ \cdots,\ o_1),$$

$$= \max_{1 \le j \le N} [\delta_t(s_j) A_{ji}] B_{io_{t+1}}$$

- 定义在时刻t状态为s_i的所有单个路径$(y_1,\ y_2,\ \ldots,\ s_i)$中概率最大的路径的第$t-1$个结点为：

$$\psi_t(s_i) = \arg\max_{1 \le j \le N} [\delta_{t-1}(s_j) A_{ji}], i = 1,\ 2,\ \ldots,\ N$$

维特比算法

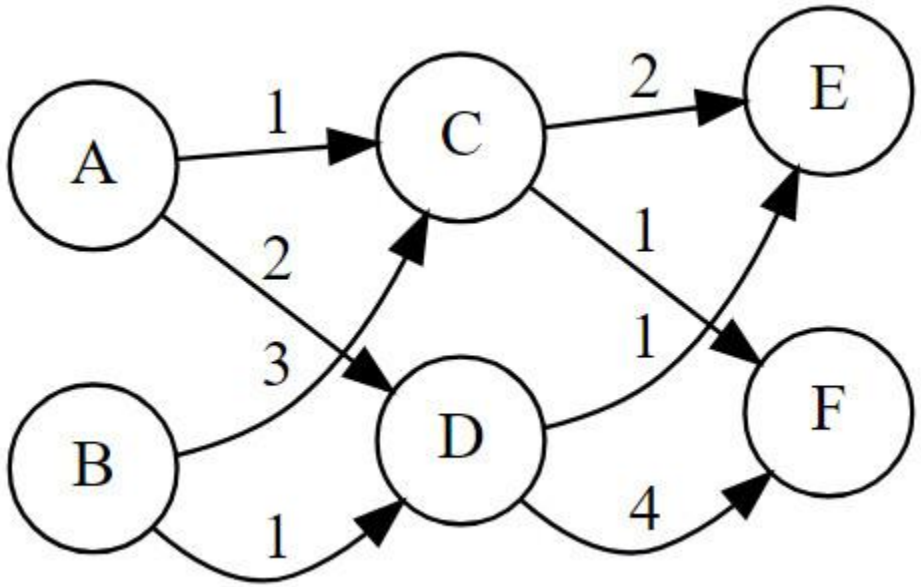

搜索状态序列的维特比算法

1) 初始化，$t = 1$时初始最优路径的备选由N个状态组成，它们的前驱为空。

$$\boldsymbol{\delta}_{1,i} = \boldsymbol{\pi}_i \boldsymbol{B}_{i,o_1}, i = 1, \cdots, N$$

$$\boldsymbol{\psi}_{1,i} = 0, i = 1, \cdots, N$$

搜索状态序列的维特比算法

2) 递推，$t \geq 2$时每条备选路径像贪吃蛇一样吃入一个新状态，长度增加一个单位，根据转移概率和发射概率计算花费。找出新的局部最优路径，更新两个数组。

$$\boldsymbol{\delta}_{t,i} = \max_{1 \leqslant j \leqslant N} (\delta_{t-1,j} \boldsymbol{A}_{j,i}) \boldsymbol{B}_{i,o_t}, i = 1, \cdots, N$$

$$\boldsymbol{\psi}_{t,i} = \arg\max_{1 \leqslant j \leqslant N} (\delta_{t-1,j} \boldsymbol{A}_{j,i}), i = 1, \cdots, N$$

搜索状态序列的维特比算法

3) 终止，找出最终时刻$\boldsymbol{\delta}_{t,i}$数组中的最大概率$p^*$，以及相应的结尾状态下标$i_T^*$。

$$p^* = \max_{1 \leqslant i \leqslant N} \boldsymbol{\delta}_{T,i}$$

$$i_T^* = \arg\max_{1 \leqslant i \leqslant N} \boldsymbol{\delta}_{T,i}$$

搜索状态序列的维特比算法

4) 回溯，根据前驱数组$\boldsymbol{\psi}$回溯前驱状态，取得最优路径状态下标$\boldsymbol{i}^* = i_1^*, \cdots, i_T^*$。

$$i_t^* = \boldsymbol{\psi}_{t+1, i_{t+1}^*},\ t = T-1, T-2, \cdots, 1$$

维特比算法

隐马尔可夫模型的三个基本应用（概率计算、学习、解码）展现了算法设计的**创新**潜力。国家在人工智能技术自立自强上的战略需求，鼓励大家勇于探索算法优化路径，突破技术瓶颈，培养创新精神。通过将技术研发与国家需求相结合，激发**个人理想**融入**科技报国**的热情，为推动我国人工智能技术在全球舞台上占据领先地位贡献智慧与力量。

例子

假设有三个盒子，每个盒子装有红白两种颜色的球，从三个盒子抽球，首先以概率(0.2, 0.4, 0.4)从三个盒子中选择一个盒子，然后从盒子中抽出一个球，记录颜色后放回。如果是盒子1，则抽出红球和白球的概率都是0.5。然后随机转移到下一个盒子，转移到三个盒子的概率分别为(0.5, 0.2, 0.3)，其它的情况的概率见下面的矩阵

$$A = \begin{pmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}, \quad B = \begin{pmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{pmatrix}, \quad \pi = (0.2, 0.4, 0.4),$$

已知观测序列O = (红，白，红)，求最优状态序列。

t=1

t=1

盒子1

$\delta_1(1) = \pi_1 b_{1o_1}$
$= 0.10$

盒子2

$\delta_1(2) = \pi_2 b_{2o_1}$
$= 0.16$

盒子3

$\delta_1(3) = \pi_3 b_{3o_1}$
$= 0.28$

t=2

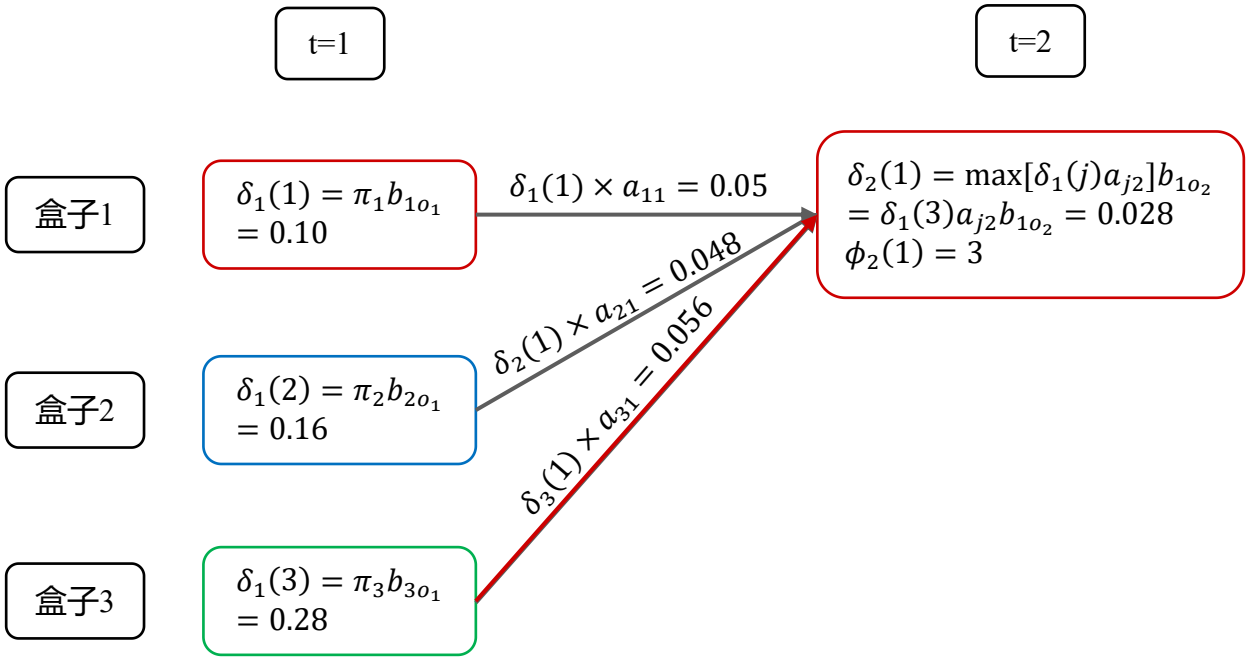
t=1
t=2
盒子1
盒子2
盒子3
$\delta_1(1) = \pi_1 b_{1o_1} = 0.10$
$\delta_1(2) = \pi_2 b_{2o_1} = 0.16$
$\delta_1(3) = \pi_3 b_{3o_1} = 0.28$
$\delta_1(1) \times a_{11} = 0.05$
$\delta_2(1) \times a_{21} = 0.048$
$\delta_3(1) \times a_{31} = 0.056$
$\delta_2(1) = \max[\delta_1(j) a_{j2}] b_{1o_2} = \delta_1(3) a_{j2} b_{1o_2} = 0.028$
$\phi_2(1) = 3$

t=2

t=1

t=2

盒子1

$\delta_1(1) = \pi_1 b_{1o_1}$
$= 0.10$

盒子2

$\delta_1(2) = \pi_2 b_{2o_1}$
$= 0.16$

盒子3

$\delta_1(3) = \pi_3 b_{3o_1}$
$= 0.28$

$\delta_2(1) = \max[\delta_1(j)a_{j2}]b_{1o_2}$
$= \delta_1(3)a_{j2}b_{1o_2} = 0.028$
$\phi_2(1) = 3$

$\delta_2(2) = \max[\delta_1(j)a_{j2}]b_{2o_2}$
$= 0.0504$
$\phi_2(2) = 3$

$\delta_2(1)$
$= \max\left[\delta_1(j)a_{j3}\right] b_{3o_2}$
$= 0.042$
$\phi_2(3) = 3$

第t+1时刻每个状态只保存从t时刻过来的N条路线中的最优路线

t=3

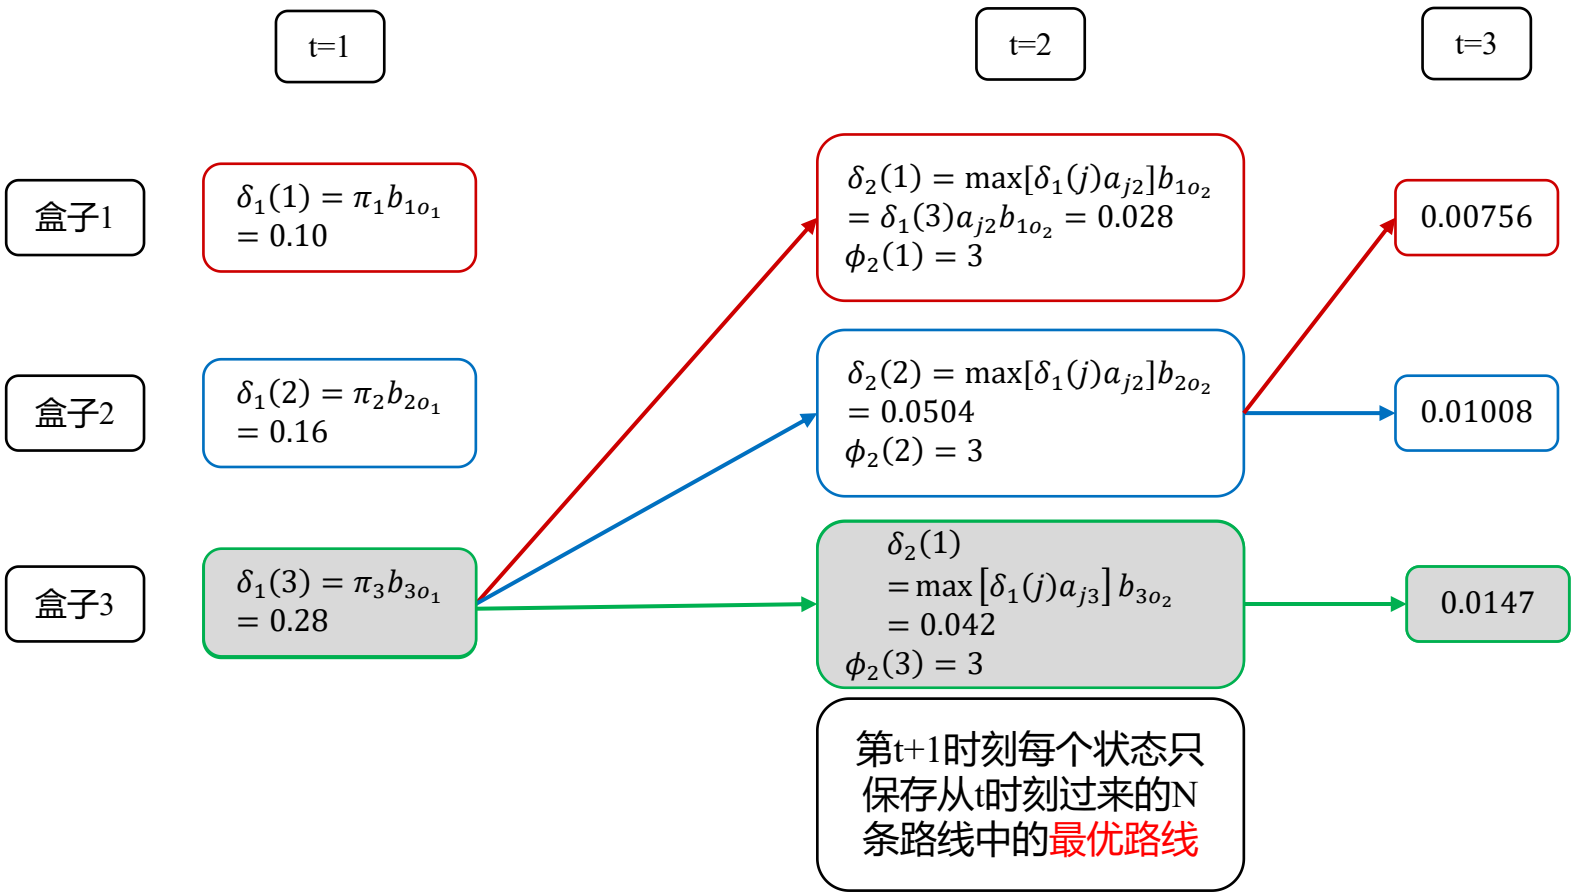
t=1
t=2
t=3
盒子1
盒子2
盒子3
$\delta_1(1) = \pi_1 b_{1o_1} = 0.10$
$\delta_1(2) = \pi_2 b_{2o_1} = 0.16$
$\delta_1(3) = \pi_3 b_{3o_1} = 0.28$
$\delta_2(1) = \max[\delta_1(j)a_{j2}]b_{1o_2} = \delta_1(3)a_{j2}b_{1o_2} = 0.028$
$\phi_2(1) = 3$
$\delta_2(2) = \max[\delta_1(j)a_{j2}]b_{2o_2} = 0.0504$
$\phi_2(2) = 3$
$\delta_2(1) = \max\left[\delta_1(j)a_{j3}\right] b_{3o_2} = 0.042$
$\phi_2(3) = 3$
0.00756
0.01008
0.0147
第t+1时刻每个状态只保存从t时刻过来的N条路线中的最优路线

Viterbi算法

```python
def viterbi(trainsition_probability,emission_probability,pi,obs_seq):

    N = np.array(trainsition_probability).shape[0] # 隐藏状态个数
    T = len(obs_seq) # 观测序列的观测个数，即时刻个数
    # 每个时刻每个状态对应的局部最优状态序列的概率值
    delta = np.zeros((N,T))
    # 保存每个时刻每个状态取到最大概率的前置节点
    phi = np.zeros((N,T),dtype = int)
    delta[:,0] = pi*np.transpose(emission_probability[:,obs_seq[0]]) #初始状态
    for t in range(1,T):
        list_max=[]
        for n in range(N):
            # 计算时刻 t,状态为n的所有单个路径的概率值
            delta_ti = delta[:,t-1]*np.transpose(trainsition_probability[:,n])
            # 保存最大概率
            list_max.append(np.max(delta_ti))
            # 保存最大概率对应的前置节点
            phi[n,t] = np.argmax(delta_ti)
        delta[:,t] = np.array(list_max)*np.transpose(emission_probability[:,obs_seq[t]])

    result = np.zeros(T)
    result[T-1] = np.argmax(delta[:,T-1])
    for t in range(T-2,-1,-1):
        result[t] = phi[int(result[t+1]),t+1]
    return result
```

什么是词性

- **词性**（Part-Of-Speech，POS）指的是单词的语法分类，也称为词类。同一个类别的词语具有相似的语法性质
- 所有词性的集合称为**词性标注集**。

r: 代词，u：助词，n：名词，v：动词，nr：人名，p：介词，a：形容词

词性

词可以分为实义词（Content Words）和功能词（Function Words）

- **实义词表达具体的意义。**由于实义词可以不断地增加，因此这类词又被称作开类词 (Open class words)。实义词主要包含名词、动词、形容词等。
- **功能词则主要是为了满足语法功能需求。**由于功能词相对比较稳定，一个语言中通常很少增加新的功能词，因此功能词又被称作闭类词 (Close Class Words)

实词分类

词性大类	词性中类	词性小类	举例	意义	对应任务	完成任务
实词	名词	专有名词	云南、上海、刘焕勇、中国	事物的特殊性	地点识别	理解语言中描述的对象
		抽象名词	思想、质量、品德、爱好	形而上的特性	人物识别	
		方位名词	上、下、左、右、前、后、中、东、西、南、北、中间	事物的空间维度	机构名识别	
		时间名词	小时、分钟、秒、年、月、日	事物的时间维度	时间识别	
		普通名词	花瓜、苹果、白菜、汽车	一般事物	领域实体识别	
	动词	一般动词	来、去、走、说、讲、跑、学习、吃饭	肢体等一般活动	动作识别	理解语言中对象的动作(动作的主观性和客观性)
		心理动词	想、重视、尊敬、瞧不起、相信、否认、佩服（可以加程度副词）	具有情感色彩的心理活动	主观性识别	
		能愿动词	能、肯、愿意、应该、可能、必须、肯定	对某个事情的主观性和能动性	确定性识别	
		趋向动词	是、为等判断动词	名词的布尔性特征	真假性识别	
	形容词	形状形容词	大、方形、圆	物体外形视觉上的认识	情感分析	理解语言中对象的外在反馈
		性质形容词	高尚、过硬、牢固	物体质地特性上的认识	色彩分析	
		颜色形容词	红、白、绿、蓝	物体在视觉上的色道认识	事物画像	
	数词	基数词	一、二、百、千、万、亿	精确数量维度	数额识别	理解语言中对象的数字信息
		序数词	第一、第二、第三	排位维度	等级识别	
		分数词	十分之一、百分之二十	比例维度，数量级递减	比例识别	
		倍数词	一倍、十倍、百倍	倍数维度，数量级递增	比例核算	
		概数词	几(个)、十来(个)、一百上下	模糊数量维度	范围识别	
	量词	单位名量词	个、张、只、支、本、台、架、辆、颗、株、头、间、把、扇	事物的个体度量标准	体量识别	理解语言对象的客观度量信息
		度量名量词	寸、尺、丈、斤、两、吨、升、斗、加仑、伏特、欧姆、立方米	事物的重量度量标准		
		动量词	次、下、回、趟、场	动作的实施频度		
	代词	人称代词	我、你 、您 、他 、她 、它 、我们 、你们 、他们 、她们 、它们 、咱们 、自己 、别人 、大家 、大伙	语言合作原则下的指代信息	指代消解	理解语言对象的引用与传递信息
		疑问代词	谁、什么 、哪（问人或事物）、哪儿 、那里 （问处所） 、几 、多少（问数量） 、多、多么 （问程度）、 怎么、 怎样 、怎么样 （问性质状态）、什么 、怎样 、什么样 （问方式行动）	语言的疑问信息	问句意图识别	
		指示代词	这 、那 （指人或事物）、这儿 、这里 、那儿 、那里 （指地点或所处位置）这会儿、那会儿 （指时间） 、这么 、这样 、这么样 、那么 、那样 、那么样（指性质、状态、方式 、行动、程度） 、这些 、那些 、这么些 、那么些 （指数量） 、每 、各（指所有的或全体中任何一个） 、某 、另、 别（确有所指，未说明哪一个）	语言合作原则下的指代信息	指代消解	

https://blog.csdn.net/lhy2014

虚词分类

词性大类	词性中类	词性小类	举例	意义	对应任务	完成任务
虚词	副词	频率副词	经常、常常、少有、偶尔	动作的实施频度	频度识别	理解语言对象的外在活动表现信息
		否定副词	没有、从未、未能、不能、不可	动作发生的布尔特性	成立性识别	
		程度副词	非常、极其、略微、稍稍、稍微、微微	动作、状态的程度信息	严重性识别	
		时间副词	立刻、马上、曾经、重新、不断	动作、状态的时间性	时间性识别	
	介词	一般介词	把、从、向、朝、为、为了、往、于、比、被、在、对、以、通过、随着、作为	事物的操作信息	介宾识别	
	连词	单连词	那么、所以、并且、或者	事物之间的逻辑关系	逻辑关系识别	理解语言对象之间的逻辑语义关系
		双连词	既……又、要么……要么、虽然……但是、因为……所以、不但……而且			
	助词	结构助词	的、地、得、所、似的			
		动态助词	着、了、过	动作或状态的时态	时态识别	理解语言对象的时态信息
		语气助词	啊、吗、呢、吧、呐、呀、了、么、哇	语气信息	语气识别	理解语言使用者的情绪
	叹词	一般叹词	喂、哟、嗨、哼、哦、哎呀	语气信息	语气识别	理解语言使用者的情绪
	拟声词	拟声词	呜、汪汪、轰隆、咯咯、沙沙沙、呼啦啦	声音模拟信息	声源识别	理解语言的听觉属性

https://blog.csdn.net/2014

名词

名词（Noun）是表示人、物、地点以及抽象概念的一类词。

例如：

1）专有名词：Shanghai（上海）New York（纽约）

2）类名词：city（城市）bird（鸟）

3）集体名词：family（家庭）army（军队）

4）物质名词：water（水）light（光）

5）抽象名词：music（音乐）honesty（诚实）

动词

动词（Verb）是表示动作或状态的一类词，是英语中最复杂的一类词。

例如：

1) Boys fly kites. （男孩们放风筝）

2）不及物动词：Birds fly. （鸟会飞）

3）连系动词：The rose smells sweet. （玫瑰花香）

4）助动词：I may have meet him before.（我以前应该见过他）

5）限定动词：John reads papers every day. （约翰每天都读论文）

6）不限定动词：I hope to see you this morning.（我希望早上见到你）

7）短语动词：Tom called up George. (汤姆给乔治打了电话)

形容词

形容词（Adjective）是用来描写或修饰名词的一类词。

例如：

1）简单形容词：

a) 由一个单词构成 good（好的）long（长的）

b) 由现在分词构成 interesting（令人感兴趣的）

c) 由过去分词构成 learned（博学的）

2）复合形容词：duty-free（免税的）hand-made（手工制作的）

3）限制性形容词：an Italian dish （一道意大利菜）

4）描述性形容词：a delicious Italian dish （一道美味的意大利菜）

副词

副词（Adverb）是用来修饰动词、形容词、其他副词以及全句的词。

例如：

1）简单副词：just（刚刚）only（仅仅）

2）复合副词：somehow（不知怎地）somewhere（在某处）

3）派生副词：interesting ‘→ ‘ interestingly （有趣地）

4）方式副词：quickly（迅速）awkwardly（笨拙地）

5）方向副词：outside（外面）inside（里面）

6）时间副词：recently（最近）always（总是）

7）强调副词：very（很）fairly（相当）

数词

数词（Numeral）是表示数目多少或者先后顺序的一类词。

例如：

1）基数词：one（1）nineteen（19）

2）序数词：first（第一）fiftieth（第五十）

代词

代词（Pronoun）是代替名词以及起名词作用的短语、子句和句子的一类词。

例如：

1）人称代词：
a) 主格：I, you, he, she, it, we, they
b) 宾格：me, you, him, her, it, us, them
2）物主代词：
a) 形容词性物主代词：my, your, his, her, its, our, their
b) 名词性物主代词：mine, yours, his, hers, its, ours, theirs
3）自身代词：myself, yourself, himself, herself, itself, ourselves, yourselves, themselves, oneself
4）相互代词：each other, one another
5）指示代词：this, that, these, those
6）疑问代词：who, whom, whose, which, what
7）关系代词：who, whom, whose, which, that, as
8）不定代词：some, something, somebody, someone, any, anything,anybody, anyone, no,
nothing, nobody, no one

冠词

冠词（Article）是置于名词之前，说明名词所指的人或事物的一种功能词。

冠词不能够离开名词而独立存在。英语中冠词有三种冠词：**定冠词**（Definite article）“the”、**不定冠词**（Indefinite article）“a/an”和**零冠词**（Zero article）。

介词

介词（Preposition）又称前置词，是用于表示名词或相当于名词的词语与句中其它词语的关系的一类词。介词在句子中不单独作为任何句子成分。介词后面的名词或者相当于名词的词语叫做介词宾语，与介词共同组合成介词短语。

例如：

1）简单介词：at, in, of, since

2）复合介词：as for, as to, out of

3）二重介词：from under, from behind

4）短语介词：according to, because of

5）分词介词：including, regarding

连词

连词（Conjunction）是连接单词、短语、从句或句子的一类词。在句子中也不单独作为句子成分。

例如：

1）简单连词：and, or, but, if

2）关联连词：both ... and, not only ... but also

3）分词连词：supposing, considering

4）短语连词：as if, as long as, in order that

5）并列连词：and, or, but, for

6）从属连词：that, whether, when, becaus

感叹词

感叹词（Interjection）是用来表示喜怒哀乐等情绪或情感的一类词。感叹词也没有实际意义，也不能在句子中构成任何句子成分，但是与全句有关联。

例如：

‘Oh ‘, it’s you. 啊，是你

‘Ah ‘，how pitiful！呀，多可惜

词性

在语言学研究中，对于词性划分的标准、依据甚至目的等都存在大量分歧。到目前为止，还**没有一个被广泛认可的统一划分标准。**

在不同的语料集中所采用的**划分粒度和标记符号也都不尽相同。**

- 英语宾州树库（Penn TreeBank）使用了 48 种不同的词性
- 汉语宾州树库（Chinese Penn Treebank）中汉语词性被划分为 33 类
- 布朗语料库（Brown Corpus）中则使用了具有 87 个词性

决定一个词词性的因素

从语言学角度：由词的用法以及在句中的语法功能决定

统计学角度：

- 和上下文的词性（前后词的标注）相关
- 和上下文单词（前后词）相关

词性的用处

- 当下游应用遇到OOV时，可以通过OOV的词性猜测用法，比如人名，nr
- 词性也可以直接用于抽取一些信息，比如抽取所有描述特定商品的形容词等，日期，数字
- 去除停用词，可以根据词性本身的特性进行去除，例如连词、助词、介词等词性
- 关键信息提取过滤，通常提取名词性成分和动词性成分

词性标注

- **词性标注**指的是为句子中每个单词预测一个词性标签的任务
- 难点：
  - 汉语中一个单词多个词性的现象很常见（称作兼类词），比如既是动词又是名词的词，希望、工作、帮助、回答、负担、爱好、比赛、游戏、生活、需要、表演、运动…
  - OOV是任何自然语言处理任务的难题

词性标注体系

宾州树库中的标注体系

标签	描述	标签	描述
CC	并列连词	CD	数字
DT	限定词	EX	there
FW	外来词	IN	介词或从属连词
JJ	形容词	JJR	形容词比较级
JJS	形容词最高级	LS	列表项标记
MD	情态助动词	NN	名词单数
NNS	名词复数	NNP	专有名词单数
NNPS	专有名词复数	PDT	前限定词
POS	所有格结束词	PRP	人称代名词
PRP$	物主代词	RB	副词
RBR	副词比较级	RBS	副词最高级
RP	小品词	SYM	符号
TO	to	UH	叹词
VB	动词	VBD	动词过去式
VBG	动词现在进行式	VBN	动词过去分词
VBP	动词一般现在式 非第三人称单数	VBZ	动词一般现在式 第三人称单数
WDT	Wh-限定词	WP	Wh-代词
WP$	所有格 Wh-代词	WRB	Wh-副词

词性标注体系

Jieba分词标注体系

标记	名称	标记	名称
a	形容词	nx	字母专名
ad	副形词	nz	其他专名
ag	形语素	o	拟声词
an	名形词	p	介词
b	区别词	q	量词
c	连词	r	代词
d	副词	s	处所词
dg	副语素	t	时间词
e	叹词	tg	时语素
f	方位词	u	助词
g	语素	ud	结构助词
h	前接成分	ug	时态助词
i	成语	uj	结构助词的
j	简称略语	ul	时态助词了
k	后接成分	uv	结构助词地
l	习用语	uz	时态助词着
m	数词	v	动词
n	名词	vd	副动词
ng	名语素	vg	动语素
nr	人名	vn	名动词
ns	地名	w	标点符号
nt	机构团体	x	非语素字
y	语气词		

https://blog.csdn.net/ty2014

词性标注模型

- 词性标注既可以看做中文分词的后续任务，也可以与中文分词集成为同一个任务。
- 同时进行多个任务的模型称为**联合模型**（joint model）

商 B-名词
品 E-名词
和 S-连词
服 B-名词
务 E-名词

联合模型遇到的问题：

- 标注语料少
- 特征数量巨大

词性标注模型

- 流水线式
  - 中文分词语料库远远多于词性标注语料库
  - 实际工程上通常在大型分词语料库上训练分词器
  - 然后与小型词性标注语料库上的词性标注模型灵活组合为一个异源的流水线式词法分析器

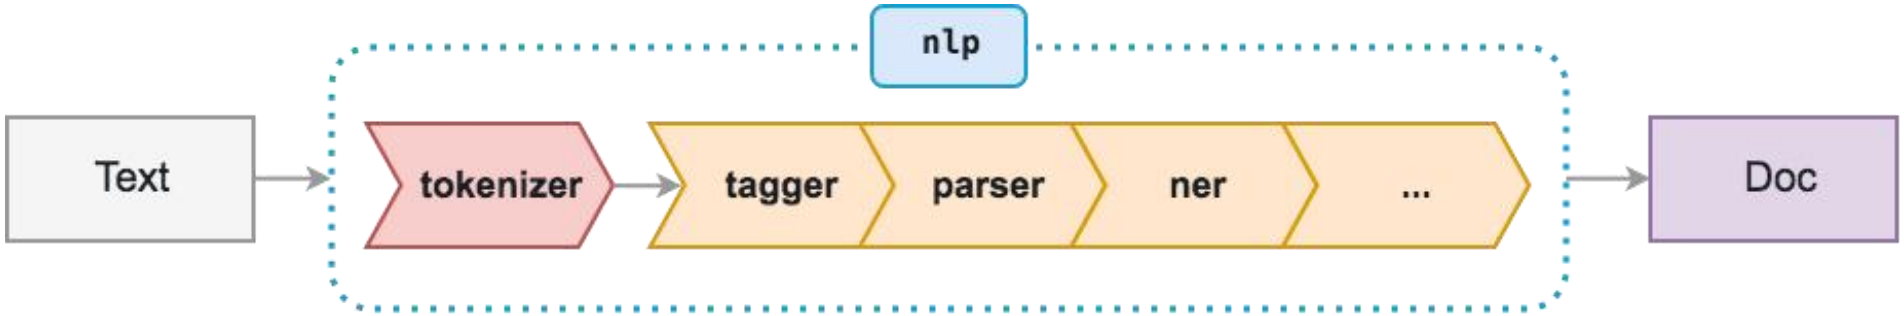

词性标注语料库与标注集

- 目前还没有一个被广泛接受的汉语词性划分标准，无论是词性划分的颗粒度还是词性标签都不统一。
- 本节选取其中一些授权宽松，容易获得的语料库作为案例，介绍其规模、标注集等特点

《人民日报》语料库与PKU标注集

- 北京大学计算语言学研究所以研究协议发布了1998年1月份的词性标注语料库。

- 语料库中的一句样例为：
  - １９９７年/t １２月/t ３１日/t 午夜/t ， /w 聚集/v 在/p 日本/ns 东京/ns 增上寺/ns 的/u 善男信女/i 放飞/v 气球/n ， /w 祈祷/v 新年/t 好运/n 。

国家语委语料库与863标注集

- 国家语言文字工作委员会建设的大型语料库
- 语料库项目启动于1991年，1998年底建成1亿字生语料和5000万字标注语料。
- 国家语委语料库的标注规范《信息处理用现代汉语词类标记集规范》在2006年成为国家标准
  - 其词类体系分为20个一级类、29个二级类

- 规模宏大，缺点是内部标注一致性不足。

《诛仙》语料库与CTB标注集

- 哈工大张梅山老师公开了网络小说《诛仙》上的标注语料
  - 远处/NN ， /PU 小竹峰/NR 诸/DT 人/NN 处/NN ， /PU 陆雪琪/NR 缓缓/AD 从/P 张小凡/NR 身上/NN 收回/VV 目光/NN ， /PU 落到/VV 了/AS 前方/NN 碧瑶/NR 的/DEG 身上/NN ， /PU 默默/AD 端详/VV 著/AS 她/PN 。/PU
- 《诛仙》语料库采用的标注集与CTB（Chinese Treebank，中文树库）相同，一共33种词类

PKU语料

```
import os
PKU98 = "pku98"
PKU199801 = os.path.join(PKU98, '199801.txt')
PKU199801_TRAIN = os.path.join(PKU98, '199801-train.txt')
PKU199801_TEST = os.path.join(PKU98, '199801-test.txt')
```

基于隐马尔科夫模型的词性标注

```
from  pyhanlp import *

HMMPOSTagger = JClass('com.hankcs.hanlp.model.hmm.HMMPOSTagger')
AbstractLexicalAnalyzer = JClass('com.hankcs.hanlp.tokenizer.lexical.AbstractLexicalAnalyzer')
CRFSegmenter = JClass('com.hankcs.hanlp.model.crf.CRFSegmenter')
FirstOrderHiddenMarkovModel = JClass('com.hankcs.hanlp.model.hmm.FirstOrderHiddenMarkovModel')

def train_hmm_pos(corpus, model):
    tagger = HMMPOSTagger(model)  # 创建词性标注器
    tagger.train(corpus)  # 训练
    return tagger

# 输入分词结果，预测词性
hmm_tagger = train_hmm_pos(PKU199801_TRAIN, FirstOrderHiddenMarkovModel())
print(', '.join(hmm_tagger.tag("他", "的", "希望", "是", "希望", "上学")))  # 预测

# 同时进行分词和词性标注
analyzer = AbstractLexicalAnalyzer(CRFSegmenter(), hmm_tagger)  # 构造词法分析器
print(analyzer.analyze("他的希望是希望上学"))  # 分词+词性标注

# 翻译词性代码
print(analyzer.analyze("他的希望是希望上学").translateLabels())
```

基于条件随机场的词性标注

```
from  pyhanlp import *

AbstractLexicalAnalyzer =
JClass('com.hankcs.hanlp.tokenizer.lexical.AbstractLexicalAnalyzer')
CRFSegmenter = JClass('com.hankcs.hanlp.model.crf.CRFSegmenter')
CRFPOSTagger = JClass('com.hankcs.hanlp.model.crf.CRFPOSTagger')

POS_MODEL = os.path.join(PKU98, 'pos.bin')

def train_crf_pos(corpus):
    tagger = CRFPOSTagger(None)  # 创建空白标注器
    tagger.train(corpus, POS_MODEL)  # 训练
    return tagger

# 训练模型比较耗时，训练以后可以暂时注释掉
tagger = train_crf_pos(PKU199801_TRAIN)

crf_tagger = CRFPOSTagger(POS_MODEL) # 加载
print(', '.join(crf_tagger.tag("他", "的", "希望", "是", "希望", "上学")))  # 预测
analyzer = AbstractLexicalAnalyzer(CRFSegmenter(), crf_tagger)  # 构造词法分析器
print(analyzer.analyze("李狗蛋的希望是希望上学"))  # 分词+词性标注
```

词性标注评测

评测的量化指标依然是精确率P、召回率R、和F_1

$$P = \frac{\text{预测正确的标签总数}}{\text{预测的标签总数}}$$

$$R = \frac{\text{预测正确的标签总数}}{\text{测试集中的标签总数}}$$

$$F_1 = \frac{2PR}{P + R}$$

可以为每个标签都计算P, R, F_1，也可笼统地计算一套值

$$Accuracy = \frac{\text{预测正确的标签总数}}{\text{标签总数}}$$

词性标注评测

```
PosTagUtil = JClass('com.hankcs.hanlp.dependency.nnparser.util.PosTagUtil')

print("HMM\t%.2f%%: " % (PosTagUtil.evaluate(hmm_tagger, PKU199801_TEST)))
print("CRF\t%.2f%%: " % (PosTagUtil.evaluate(crf_tagger, PKU199801_TEST)))
```

算法	准确率
一阶隐马尔可夫模型	44.99%
二阶隐马尔可夫模型	40.53%
结构化感知机	83.07%
条件随机场	82.12%